

# 从统计数据分析信息学竞赛

江苏省天一中学 邱天异

## 摘要

本文建立了描述信息学比赛的数学模型，基于该模型研究了过往比赛的统计数据，并在此基础上进行推演。本文测量确定了同一名选手的得分波动所服从的分布，基于此从联赛分数推算出了选手整体水平的分布情况，并研究了分级选拔流程的优化方式、回答了有关比赛名次与得分的问题。本文中得到的结论对信息学竞赛流程的优化、选手的日常训练和比赛策略制定具有参考意义。

## 1 引言

中国高中信息学竞赛的参赛人数和竞赛水平在最近十年中快速提高；这种迅猛的发展在让竞赛趋于繁盛的同时，也使得选手和教练对竞赛现状的认知难以跟上节拍。认知的落后引起了一些问题，例如：

- 选手对于自己所处的水平段认识不足，从而作出错误的学业规划。
- 出题人对于选手的水平认识不足，导致题目难度和部分分分配失当。
- 选手不了解对手的水平 and 发挥情况，导致选择了错误的考场策略。

本文将利用数学工具，基于过往比赛的统计数据来分析信息学竞赛的现状和其中的规律，以为上述问题的解决提供助力。

本文中用到的全部数据和计算程序可以在以下网址下载：

- <https://files.cnblogs.com/files/turboboost/qty-thesis-statdata.zip>
- <https://github.com/TianyiQ/ioi2021-thesis/blob/main/qty-thesis-statdata.zip>

正文分为五个部分：

**第二节** 建立用于描述信息学比赛的数学模型，作为后续分析的基础。

**第三节** 测量同一名选手的得分波动所服从的分布。

**第四节** 利用联赛初赛、复赛的得分数据推算出信息学竞赛选手整体水平的分布情况。

**第五节** 对于在比赛名次中出现的现象进行讨论。

**第六节** 对于“分级选拔”的选拔方式，提出方法来合理地设置选拔流程。

由全文的目标决定，本文将不会对初中信息学竞赛进行研究，因此下文在提到任何比赛时默认指面向高中生的比赛。

## 2 建立模型

### 2.1 赛程和赛制

在引入模型前，先对信息学竞赛的竞赛流程和比赛形式作简要介绍<sup>1</sup>。

信息学竞赛是一系列比赛的统称。这些比赛整体上呈现“逐级递进”的关系，即下一层比赛的优胜者晋级上一层比赛。这些比赛按照级别从低到高，大致排列为<sup>2</sup>：

- a. 全国联赛 (NOIP/CSP) — 初赛
- b. 全国联赛 (NOIP/CSP) — 复赛
- c. 省队选拔赛
- d. 清华/北大学科营 (THUWC/PKUWC/THUSC/PKUSC)
- e. 亚太地区竞赛 (APIO)
- f. 国家队选拔赛 (CTSC/CTS) — 非正式选手
- g. 全国冬令营 (NOIWC) — 非正式选手
- h. 全国决赛 (NOI)
- i. 清华/北大集训 (CTT)
- j. 全国冬令营 (NOIWC) — 正式选手
- k. 国家队选拔赛 (CTSC/CTS) — 正式选手
- l. 国际奥林匹克竞赛 (IOI)

图 1 展示了这些比赛间的关系。箭头从低级别比赛指向高级别比赛，表示该低级别比赛的优胜者可以晋级对应的高级别比赛，箭头上标记的数值表示大致晋级人数。

赛制即比赛的进行方式和比赛规则。信息学竞赛中采用笔试、COI 赛制（机试）、IOI 赛制（机试）这三种不同的赛制，表 1 给出了每种赛制的特点和先前提到的比赛所分别采用的赛制。

	时长	题数	题目类型	反馈机制	对应比赛
笔试	1~2h	数十	选择题、填空题	无反馈	a
COI 赛制	3~5h	3~4	编程题，有多档部分分	无反馈	b, c, f, g, h, k
IOI 赛制	3~5h	3~4	编程题，有多档部分分	多次提交、有反馈	d, e, i, j, l

表 1: 信息学比赛采用的赛制

<sup>1</sup>赛程和赛制在近几年有小幅变化，本小节中会尽量兼顾新旧两套机制

<sup>2</sup>后文将用下表中的字母标号来代指对应的比赛




图 1: 信息学比赛间的关系

## 2.2 数学模型

本小节中将建立用于描述一场信息学比赛的数学模型。

### 2.2.1 基本模型

为了更清晰地界定模型在现实中的适用范围，需要先明确：现实中怎样的对象能被称为一场“比赛”。

**定义 2.1 (现实比赛).** 一个现实比赛，即特定的人群在同样的规则下测试同一套题目的过程。一个现实比赛被参赛人群、规则和题目这三个要素所确定。

在这一定义下，每年中的  $a \sim l$  这 12 个比赛，自然都是现实比赛。而且，不仅是包含两天考试的一场完整的比赛算作现实比赛，单独拿出其中一天也算现实比赛。

关于“参赛人群”这一概念需要注意两点：

- 参赛人群只是一个宽泛的范围，而不是具体的选手集合。例如我们可以规定参赛人群为“所有学习信息学的同学”，但这一规定并不关注张三、李四、王五是否是这个人群的成员。这样的规定不会给后续的分析带来不利影响，因为我们只关心关于比赛和人群的统计信息，而不关心每名选手的特点。
- 参赛人群不必囊括实际参赛的整个选手群体；例如在 NOIP 初赛，“所有报名了初赛的女生”这一参赛群体依然能构成现实比赛。这一点对于后文中跨越不同比赛的分析大有帮助。

接下来定义从现实比赛抽象而来的数学模型。

**定义 2.2** (理想比赛). 理想比赛  $A$  由二元函数  $\mathcal{H}_A : [0, 1] \times \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$  确定, 其中  $\mathcal{H}_A$  连续且满足

$$\int_0^1 \int_{-\infty}^{+\infty} \mathcal{H}_A(x, \delta) d\delta dx = 1 \quad (1)$$

和

$$\int_{-\infty}^{+\infty} \delta \cdot \mathcal{H}_A(x_0, \delta) d\delta = 0, \quad \forall x_0 \in [0, 1] \quad (2)$$

此时我们把  $\mathcal{H}_A$  称为  $A$  的综合分布函数。

接下来将定义: 一个理想比赛何时被认为“描述”了一个现实比赛。这也将同时表明综合分布函数的实际含义。

首先约定一下记号:

- $\Pr[A]$  表示事件  $A$  发生的概率。
- $E[X]$  表示随机变量  $X$  的期望值。

**定义 2.3.** 从现实比赛  $B$  可按如下方式确定一个理想比赛  $A$ :

**步骤 1.** 记  $B$  的参赛选手集合为有限集  $S_B$ , 并在  $B$  的参赛人群 (包括人群内部的具体构成) 不变的情况下, 假想参赛人数  $|S_B|$  趋于无穷。我们之所以能够任意钦定  $|S_B|$ , 是因为——如先前所述—— $B$  的定义并未指明具体的选手集合。

**步骤 2.** 每一名参赛选手  $p$  在比赛  $B$  中的实际得分  $score_p$  是一个随机变量, 它被各种偶然因素 (如临场发挥) 所支配, 但是它的分布可以由选手  $p$  和现实比赛  $B$  的三个要素完全确定。假想对每一名选手  $p$  计算其期望得分  $exscore_p = E[score_p]$ , 并取所有选手期望得分的最大值, 记作  $M_B$ 。由于参赛人数趋于无穷, 每一个个人的特征可以忽略, 故  $M_B = \max_{p \in S_B} exscore_p$  仅由  $B$  确定。

**步骤 3.** 从  $S_B$  中等概率随机选取一名选手  $p$ , 并:

- 定义在  $[0, 1]$  中取值的随机变量  $X_B = \frac{exscore_p}{M_B}$ 。<sup>3</sup> 易见随机变量  $X_B$  的实际取值与考场上的偶然因素无关, 而是由选取  $p$  的方式确定。
- 定义在  $\mathbb{R}$  中取值的随机变量  $\Delta_B = \frac{score_p - exscore_p}{M_B}$ 。易见随机变量  $\Delta_B$  的实际取值由选取  $p$  的方式和考场上的偶然因素 (如选手临场发挥) 共同确定。
- 请注意,  $X_B$  和  $\Delta_B$  的定义中所用的  $p$  是同一名随机选择的选手, 而不是独立的两次选择。

<sup>3</sup> “将每名选手的分数除以最高分数”这一操作, 类似于信息学比赛中计算标准分的方式。另外注意到: 虽然  $\frac{exscore_p}{M_B} \leq 1$ , 但  $\frac{score_p}{M_B}$  可以大于 1

**步骤 4.** 取  $A$  的综合分布函数  $\mathcal{H}_A$  为  $X_B$  与  $\Delta_B$  的联合概率密度函数, 从而确定  $A$ 。换句话说, 对所有  $x_0 \in [0, 1], \delta_0 \in \mathbb{R}$ , 需要满足<sup>4</sup>

$$\int_0^{x_0} \int_{-\infty}^{\delta_0} \mathcal{H}_A(x, \delta) d\delta dx = \Pr[(X_B \leq x_0) \wedge (\Delta_B \leq \delta_0)] \quad (3)$$

由(3)知定义 2.2 的等式(1)满足; 由  $E[\Delta_B] = 0$  知等式(2)满足。从而只要联合概率密度函数  $\mathcal{H}_A$  存在且连续,  $A$  就符合理想比赛的定义。

对于按上述方式得到的  $A$ , 我们称  $A$  与  $B$  **互相对应**。如果按上述过程得到的  $\mathcal{H}_A$  不连续或根本不存在, 则认为不存在与  $B$  对应的  $A$ 。

冗长的定义可以用一句话来作直观的总结:  $\mathcal{H}_A(x, \delta)$  表示真实水平 (即期望得分) 约为  $x$  ( $x \in [0, 1]$  为按最高分折算后的标准分)、实际表现约为  $x + \delta$  (同样表示标准分) 的选手的期望人数占总人数的比例; 之所以实际表现会偏离真实水平——以及这里之所以说“期望人数”——是因为考场上的各种偶然因素为比赛结果带来了随机性。

可以看到, 理想比赛这一模型只考虑了哪些结果可能出现, 而未考虑哪种结果实际出现。而在现实中, 能够获知的却只有实际出现的结果——和它恰恰相反。下面定义的概念将处理这一问题。

**定义 2.4** (分数分布函数). 对理想比赛  $A$ , 定义其分数分布函数  $C_A: \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$  满足

$$C_A(s) = \int_0^1 \mathcal{H}_A(x, s - x) dx, \quad \forall s \in \mathbb{R}$$

**命题 2.5** (分数分布函数的实际含义). 对现实比赛  $B$  和与之对应的理想比赛  $A$ , 假想比赛  $B$  的参赛人数  $|S_B|$  趋于无穷, 等概率随机选取选手  $p \in S_B$ , 则<sup>5</sup>:

$$\Pr\left[\frac{\text{score}_p}{M_B} \leq r\right] = \int_{-\infty}^r C_A(s) ds, \quad \forall r \in \mathbb{R}$$

<sup>4</sup>也可以直观地理解为  $\mathcal{H}_A(x_0, \delta_0) = \Pr[(X_B \approx x_0) \wedge (\Delta_B \approx \delta_0)]$ , 不写作  $X_B = x_0$  是因为取等概率为 0

<sup>5</sup>也就是说  $C_A$  为随机变量  $\frac{\text{score}_p}{M_B}$  的概率密度函数。和先前类似, 这里也可以直观理解为  $C_A(r) = \Pr\left[\frac{\text{score}_p}{M_B} \approx r\right]$

证明.

$$\begin{aligned}
 \Pr \left[ \frac{\text{score}_p}{M_B} \leq r \right] &= \Pr [X_B + \Delta_B \leq r] \\
 &= \iint_{\{(x, \delta): x \in [0, 1], \delta \in \mathbb{R}, x + \delta \leq r\}} \mathcal{H}_A(x, \delta) d(x, \delta) \\
 &= \iint_{\{(x, s): x \in [0, 1], s \in (-\infty, r]\}} \mathcal{H}_A(x, s - x) d(x, s) \\
 &= \int_{-\infty}^r \left( \int_0^1 \mathcal{H}_A(x, s - x) dx \right) ds \\
 &= \int_{-\infty}^r C_A(s) ds
 \end{aligned}$$

□

在上面四个定义中，涉及到现实情况的部分难免有模糊之处；实际应用中对这几条定义的执行，也不可避免地需要作近似处理。但即便如此，作出这些规定依然能极大地帮助我们厘清思路并发现隐含的前提。

### 2.2.2 特殊情况下的模型

在一场现实比赛  $B$  中，每一个选手  $p \in S_B$  的实际得分相比真实水平的“得分偏移量”  $\frac{\text{score}_p - \text{exscore}_p}{M_B}$  都是一个随机变量。如果所有选手的“得分偏移量”独立同分布，对我们的模型意味着什么？

容易想到，此时随机变量  $\Delta_B$  的概率分布就和任何一个选手的“得分偏移量”的概率分布完全相同。换句话说，在定义 2.3 的步骤 3 中，不论我们钦定选取哪一个  $p$ ， $\Delta_B$  取任何一个值的概率都是固定的，且恰好等于在不固定  $p$  的情况下  $\Delta_B$  取这个值的概率。再换句话说<sup>6</sup>：

$$\Pr [(\Delta_B \leq \delta) | (X_B = x)] = \Pr [\Delta_B \leq \delta], \forall (\delta \in \mathbb{R}, x \in [0, 1], \Pr [X_B = x] > 0)$$

即随机变量  $X_B, \Delta_B$  独立。在研究这件事之前，我们需要一对新的定义。

**定义 2.6** (期望值分布函数和偏移量分布函数). 对任意的理想比赛  $A$ ：

- 定义其期望值分布函数  $\mathcal{X}_A : [0, 1] \rightarrow \mathbb{R}_{\geq 0}$  满足

$$\mathcal{X}_A(x_0) = \int_{-\infty}^{+\infty} \mathcal{H}_A(x_0, \delta) d\delta, \quad \forall x_0 \in [0, 1]$$

<sup>6</sup>和之前类似，这里之所以不写  $\Delta_B = \delta$ ，是因为取等概率为 0。以及， $\Pr [X_B = x] > 0$  是不严谨的写法，这里用以表达  $X_B$  在  $x$  处概率密度大于 0

- 定义其偏移量分布函数  $\mathcal{D}_A : \mathbb{R} \rightarrow \mathbb{R}_{\geq 0}$  满足

$$\mathcal{D}_A(\delta_0) = \int_0^1 \mathcal{H}_A(x, \delta_0) dx, \quad \forall \delta_0 \in \mathbb{R}$$

**命题 2.7** (期望值分布函数和偏移量分布函数的实际含义). 对现实比赛  $B$  和与之对应的理想比赛  $A$  :

- $\mathcal{X}_A$  为  $X_B$  的概率密度函数。换句话说<sup>7</sup>:

$$\Pr[X_B \leq x_0] = \int_0^{x_0} \mathcal{X}_A(x) dx, \quad \forall x_0 \in [0, 1]$$

- $\mathcal{D}_A$  为  $\Delta_B$  的概率密度函数。换句话说<sup>8</sup>:

$$\Pr[\Delta_B \leq \delta_0] = \int_{-\infty}^{\delta_0} \mathcal{D}_A(\delta) d\delta, \quad \forall \delta_0 \in \mathbb{R}$$

证明比较显然, 这里略去。下面考虑  $X_B, \Delta_B$  间的独立性带来的性质。

**命题 2.8.** 对现实比赛  $B$  和与之对应的理想比赛  $A$  , 如果  $X_B$  与  $\Delta_B$  独立, 则:

$$\mathcal{H}_A(x_0, \delta_0) = \mathcal{X}_A(x_0) \mathcal{D}_A(\delta_0), \quad \forall (x_0, \delta_0) \in [0, 1] \times \mathbb{R} \quad (4)$$

更进一步, (4)是  $X_B$  与  $\Delta_B$  独立的充要条件。

证明.

$$\begin{aligned} & \Pr[(\Delta_B \leq \delta_0) | (X_B = x_0)] = \Pr[\Delta_B \leq \delta_0], \quad \forall (\delta_0 \in \mathbb{R}, \mathcal{X}_A(x_0) > 0) \\ \Leftrightarrow & \left( \int_{-\infty}^{\delta_0} \mathcal{H}_A(x_0, \delta) d\delta \right) / \mathcal{X}_A(x_0) = \int_{-\infty}^{\delta_0} \mathcal{D}_A(\delta) d\delta, \quad \forall (\delta_0 \in \mathbb{R}, \mathcal{X}_A(x_0) > 0) \\ \Leftrightarrow & \frac{\mathcal{H}_A(x_0, \delta_0)}{\mathcal{X}_A(x_0)} = \mathcal{D}_A(\delta_0), \quad \forall (\delta_0 \in \mathbb{R}, \mathcal{X}_A(x_0) > 0) \\ \Leftrightarrow & (4) \end{aligned}$$

最后一步中还需要特别考虑  $\mathcal{X}_A(x_0) = 0$  的情况, 不难自行补全。  $\square$

**定义 2.9** (简单理想比赛). 如果理想比赛  $A$  满足 (4) 式, 则称它是简单的。

<sup>7</sup>也可以直观地理解为:  $\Pr[X_B \approx x_0] = \mathcal{X}_A(x_0)$

<sup>8</sup>也可以直观地理解为:  $\Pr[\Delta_B \approx \delta_0] = \mathcal{D}_A(\delta_0)$

由命题 2.8, 对于简单理想比赛  $A$ , 从  $\mathcal{X}_A, \mathcal{D}_A$  可唯一确定  $\mathcal{H}_A$ , 进而能够确定  $C_A$ 。

**命题 2.10** (简单理想比赛的分数分布函数). 对简单理想比赛  $A$ :

$$C_A(s) = \int_0^1 \mathcal{X}_A(x) \mathcal{D}_A(s-x) dx, \quad \forall s \in \mathbb{R}$$

证明显然, 这里略去。

## 2.3 几个关键的假设

为了使得后续分析成为可能, 我们还需要对真实情况作一些近似处理。近似处理的具体方式由本小节的几个假设给出。

**假设 2.11.** 对任何一个信息学（现实）比赛  $B$ , 都存在符合定义 2.2 的理想比赛  $A$  与其对应。

**假设 2.12.** 对任何一个现实比赛, 如果它的规则基于 COI 或 IOI 赛制, 则它对应的理想比赛是简单的。

**假设 2.13.** 考虑所有基于 COI 或 IOI 赛制的现实比赛, 考察它们对应的理想比赛的偏移量分布, 这些分布应该是相似的, 即它们应该有相同的形式, 即使其中的参数可能有不同的取值。

在给出下一个假设之前, 还需要定义一个概念。

**定义 2.14** (缩放等价). 对简单理想比赛  $A_1, A_2$ , 当存在线性映射  $f(x) = \alpha x + \beta$  ( $\alpha \in \mathbb{R}_{>0}, \beta \in \mathbb{R}$ ) 同时满足以下条件时, 称  $A_1, A_2$  缩放等价, 称  $f$  为  $A_1, A_2$  间的等价映射:

1.  $f(1) = 1$
2.  $\mathcal{D}_{A_2}(\alpha\delta) = \mathcal{D}_{A_1}(\delta) \cdot \alpha^{-1}, \quad \forall \delta \in \mathbb{R}$
3.  $\bar{\mathcal{X}}_{A_2}(f(x)) = \bar{\mathcal{X}}_{A_1}(x) \cdot \alpha^{-1}, \quad \forall x \in \mathbb{R}$ , 其中

$$\bar{\mathcal{X}}(x) = \begin{cases} 0 & x \notin [0, 1] \\ \mathcal{X}(x) & x \in [0, 1] \end{cases}$$

如果上述映射  $f$  只满足条件 1 和 3, 则称  $A_1, A_2$  弱缩放等价, 称  $f$  为  $A_1, A_2$  间的弱等价映射。

**命题 2.15** (缩放等价的实际含义). 对缩放等价的  $A_1, A_2$  及其等价映射  $f$ , 有以下关系<sup>9</sup>:

<sup>9</sup>可以直观理解为:  $A_1$  中的分数, 经过  $f: x \mapsto \alpha x + \beta$  的变换之后, 变成了  $A_2$  中的分数



$$\begin{aligned}
1. \quad & \int_{-\infty}^{\delta_0} \mathcal{D}_{A_1}(\delta) d\delta = \int_{-\infty}^{\alpha\delta_0} \mathcal{D}_{A_2}(\delta) d\delta, \quad \forall \delta \in \mathbb{R} \\
2. \quad & \int_{-\infty}^{x_0} \bar{\mathcal{X}}_{A_1}(x) dx = \int_{-\infty}^{f(x_0)} \bar{\mathcal{X}}_{A_2}(x) dx, \quad \forall x \in \mathbb{R}
\end{aligned}$$

对于弱缩放等价类似。

证明. 先来看关于  $\mathcal{D}_{A_1}, \mathcal{D}_{A_2}$  的部分:

$$\begin{aligned}
\int_{-\infty}^{\delta_0} \mathcal{D}_{A_1}(\delta) d\delta &= \int_{-\infty}^{\delta_0} \mathcal{D}_{A_2}(\alpha\delta) \alpha d\delta \\
&= \int_{-\infty}^{\alpha\delta_0} \mathcal{D}_{A_2}(\alpha\delta) \alpha d(\alpha\delta) \cdot \alpha^{-1} \\
&= \int_{-\infty}^{\alpha\delta_0} \mathcal{D}_{A_2}(t) dt
\end{aligned}$$

对于  $\bar{\mathcal{X}}_{A_1}, \bar{\mathcal{X}}_{A_2}$  同理, 这里不再重复。 □

**假设 2.16.** 对现实比赛  $B_1$  (对应理想比赛  $A_1$ ) 和  $B_2$  (对应理想比赛  $A_2$ ), 如果

1.  $B_1, B_2$  的规则都基于 COI 或 IOI 赛制
2.  $B_1, B_2$  的规则在除了赛制外的各方面均相同
3.  $B_1, B_2$  的参赛人群相同

则  $A_1, A_2$  一定缩放等价。如果  $B_1, B_2$  满足条件 1 和 3, 则  $A_1, A_2$  一定弱缩放等价。

对这些假设无法予以严格的证明, 但在此可以列举一些感性的理由, 来说明它们大体上是可靠的。

1. 如果假设所有比赛在考查角度上没有差异 (因为我们只关心普遍的统计特征, 所以这种假设是合理的), 那么一名选手的解题能力 (即, 能够在比赛中解出多大难度的题目) 就一定是固定的。

2. 当组题人为一场比赛选择题目、出题人为命制的题目设置部分分时, 他们会有意识地给较难的任务设置较高的分值、给较简单的任务设置较低的分值, 而具体多高、多低, 则取决于他们心中作的判断。虽然不同的人可能作出不一样的判断, 但这些判断应该大体上是“成比例”的。例如: 张三认为算法 2 应当获得三倍于算法 1 的得分、李四认为算法 2 应当获得 2.5 倍于算法 1 的得分, 这两种判断在比例上是大致相符的。

3. 综合 1 和 2, 我们知道了: 每个选手的能力可以看作是不变的; 选手比赛中完成的任务难度与所获分数间的关系, 这一关系在不同比赛之间应该是“成比例”的。所以只要选手集合不变, 不同比赛的“选手期望得分构成的分布”也应该是“成比例”的 (特别地, 这

两个分布的最大值也应该是相对应的，所以在定义 2.14 中要求  $f(1) = 1$ 。这就为假设 2.16 关于期望值分布的部分和对  $f(1) = 1$  的要求提供了依据。

4. 根据经验，一名选手考场发挥的稳定与否与水平高低等因素没有明显的相关性；所以虽然不同选手的稳定性存在差异，但是在样本很大时，这种差异不会给统计结果带来较大的系统性的偏差，因此我们近似地认为所有选手水平发挥的稳定性是相同的。又因为得分与实际表现出的能力是“成比例”的，所以所有选手比赛得分的稳定性也是相同的。这为假设 2.12 和假设 2.13 提供了依据。

5. 不同的比赛因为比赛天数、试题数目等的不同，可能导致选手得分稳定性的不同（一般来说比赛天数越多，选手得分越稳定）。但如果两场比赛的天数、题数（算作比赛规则的一部分）等都相同，就可以用 4 中的论证，来为假设 2.16 关于偏移量分布的部分提供依据。

6. 真实的比赛中“离散”的特性——比如选择题三分一道——可以在理想化的模型中忽略。这样在人数趋于无穷时，我们很容易想到：其各种统计数据会是“连续”的。因此 2.11 是一个很自然的假设。

7. 根据经验，在 COI 赛制中表现好的选手，在 IOI 赛制往往表现也很好；反之亦然。因此 COI/IOI 赛制间的差异至多会对选手期望得分的分布起到缩放的作用，而不会带来本质的改变。类似地，选手在 COI/IOI 赛制中发挥稳定性的差异，也只有量的差别而无质的差别。所以，认为 COI/IOI 赛制的比赛有着本质相同（即在缩放后完全相同）的期望值分布、偏移量分布，是合理的。

8. 假设 2.12 会带来一个问题：如果一名选手的期望得分十分接近 0，但他的分数波动的幅度仍被认为与其他选手相同，就会使他可能考出“负分数”，并使得分数分布函数在负数处的点值非零。由于本文只研究近似的结果，且考虑到该现象并不会十分显著（因为一场比赛中只会有很少的选手期望得分接近 0），所以可以容忍这一不合理的现象。

### 3 偏移量分布的测量

由假设 2.13，COI/IOI 赛制下偏移量分布有一定的形式。本节中，将利用过往比赛的分数数据得到偏移量分布的形式。

#### 3.1 数据的获取

数据来自以下三场比赛：

- 2018 年北大集训（字母标号 i）
- 2019 年北大集训（字母标号 i）
- 2020 年北大集训（字母标号 i）

选用它们的原因是，北大集训包含连续进行的四场考试，更多的考试场数使得我们能够更精确地估计每一名选手的期望分数。

这些比赛的参赛情况见表 2。

	参赛总人数	正式选手人数	非正式选手人数	选拔人数
北大集训 2018	约 60	50	约 10	15
北大集训 2019	约 70	50	约 20	15
北大集训 2020	约 90	50	约 40	30

表 2: 三场比赛的参赛情况

根据经验判断,这三场比赛中并非所有选手都全情投入。因此为了保证数据可靠性,对每场比赛只取总排名<sup>10</sup>中最靠前的  $1.5K \sim 2K$  名选手的数据,其中  $K$  表示当场比赛的选拔人数。具体地说:北大集训 2018 取前 30 名、北大集训 2019 取前 30 名、北大集训 2020 取前 50 名。另外为保证比赛之间的统一性,后文中在计算比赛分数标准差时,每场比赛只取总排名中前 30 名的分数。

### 3.2 数据的加工处理

三场比赛的参赛选手共计 110 人次,我们将他们视为 110 名不同的选手。三场比赛共计 12 场考试,我们将它们视为 12 个不同的现实比赛。参加这些现实比赛的共计 440 人次。

虽然这 12 个现实比赛的参赛人群是相同的(国家集训队选手和精英培训选手),但它们在题目难度等方面并不相同,如果直接将它们的数据汇总起来的话,会使得数据失去意义。为解决这一问题,我们需对比赛得分进行变换。

**命题 3.1.** 对缩放等价的理想比赛  $A_1, A_2$  及其等价映射  $f(x) = \alpha x + \beta$ , 有

$$\alpha = \frac{\text{Stddev}[C_{A_2}]}{\text{Stddev}[C_{A_1}]}$$

其中  $\text{Stddev}[F]$  表示以  $F$  为概率密度函数的随机变量<sup>11</sup>的标准差。

在上述命题中,由  $f(1) = 1$  可得  $f(x) = 1 - \alpha(1 - x)$ , 所以不必再考虑  $\beta$  的取值。

<sup>10</sup>总排名中按每天标准分总和降序排列

<sup>11</sup>换句话说,这样的随机变量  $Y$  满足  $\Pr[Y \leq t] = \int_{-\infty}^t F(s)ds, \quad \forall t \in \mathbb{R}$

证明.

$$\begin{aligned}
 C_{A_1}(s) &= \int_0^1 \mathcal{X}_{A_1}(x) \mathcal{D}_{A_1}(s-x) dx \\
 &= \int_{-\infty}^{+\infty} \bar{\mathcal{X}}_{A_1}(x) \mathcal{D}_{A_1}(s-x) dx \\
 &= \int_{-\infty}^{+\infty} (\bar{\mathcal{X}}_{A_2}(\alpha x + \beta) \cdot \alpha) (\mathcal{D}_{A_2}(\alpha(s-x)) \cdot \alpha) dx \\
 &= \int_{-\infty}^{+\infty} \alpha^2 \bar{\mathcal{X}}_{A_2}(\alpha x + \beta) \mathcal{D}_{A_2}(\alpha s + \beta - (\alpha x + \beta)) d(\alpha x + \beta) \cdot \alpha^{-1} \\
 &= \alpha \int_{-\infty}^{+\infty} \bar{\mathcal{X}}_{A_2}(t) \mathcal{D}_{A_2}((\alpha s + \beta) - t) dt \\
 &= \alpha C_{A_2}(\alpha s + \beta), \quad \forall s \in \mathbb{R}
 \end{aligned}$$

设连续型随机变量  $Y_1$  满足其概率密度函数为  $C_{A_1}$ ， $Y_2$  满足其概率密度函数为  $C_{A_2}$ ，则  $\alpha Y_1 + \beta$  与  $Y_2$  同分布。从而<sup>12</sup>  $\text{Var}[Y_2] = \text{Var}[\alpha Y_1 + \beta] = \alpha^2 \cdot \text{Var}[Y_1]$ ，于是  $\text{Stddev}[Y_2] = \alpha \cdot \text{Stddev}[Y_1]$ 。□

结合等价映射的实际含义和命题 3.1，可以得到对前述 12 个现实比赛  $B_{1\dots 12}$  的分数做变换的方法：

**步骤 1.** 记  $B_{1\dots 12}$  对应的理想比赛为  $A_{1\dots 12}$ 。

**步骤 2.** 构造  $A'_{1\dots 12}$  满足  $A_i$  与  $A'_i$  缩放等价，且等价映射为  $f_i(x) = 1 - \frac{1-x}{c \cdot \text{Stddev}[C_{A_i}]}$ 。这里  $c = 4$  为根据实际数据所选取的固定常数，用来避免产生负分数。

**步骤 3.** 则  $A'_{1\dots 12}$  这 12 个理想比赛完全相同（即它们的综合分布函数相同），且与  $A_{1\dots 12}$  中的每一个缩放等价。

另外须注意，根据定义 2.3 的步骤 2，我们需要对每个现实比赛  $B_i$  确定选手期望分数的最大值  $M_{B_i}$ 。这里可以用实际分数的最大值来近似地代替期望分数的最大值。

因为  $A'_{1\dots 12}$  与  $A_{1\dots 12}$  中的每一个缩放等价，所以我们只需测量  $A'_{1\dots 12}$  的偏移量分布，即可得到结论。现在开始目标将转为测量  $A'_{1\dots 12}$  的偏移量分布；为便于表述，记  $B'_{1\dots 12}$  表示  $A'_{1\dots 12}$  对应的现实比赛。

现在我们得到了 12 个完全相同的理想比赛  $A'_{1\dots 12}$ ，和每个理想比赛对应的现实比赛的分数数据；而因为  $A'_{1\dots 12}$  完全相同，所以所有这些分数数据可以直接合并。现在我们有了一

<sup>12</sup>这里  $\text{Var}[Y]$  表示随机变量  $Y$  的方差

个理想比赛（记为  $A'$ ，对应现实比赛  $B'$ ）和对应的 440 名选手的分数数据。原先的 110 名选手，每人对应着  $B'$  中的 4 名选手。

对于 110 名选手中的每一位，为了能够对比他在  $B'$  中的期望分数和他的四个“分身”的实际分数，我们还需要估算前者的值。这里可以用该名选手在他所参加的 4 场现实比赛  $B'_i$  中的平均分，来近似地代替在  $B'$  中的期望分数。

综上所述，我们会按如下的流程来加工分数数据：

**步骤 1.** 对 12 场比赛中的每一场，将其中每一名选手的分数除以该场比赛的最高分<sup>13</sup>，并以此代替原始分数。

**步骤 2.** 对 12 场比赛中的每一场，计算总排名前 30 的选手的分数标准差  $\sigma$ （这里的分数是指步骤 1 中得到的商），然后将其中每个选手的分数  $x$  施以变换<sup>14</sup>  $x \mapsto 1 - \frac{1-x}{4\sigma}$ ，并以此代替原始分数。

**步骤 3.** 对 110 名选手中的每一位，计算他在 4 场比赛中的平均分，然后计算他在每场比赛中的得分与这一平均分的差。

这样可以对每名选手计算出 4 个差值，共计 440 个值，每个值都表示一名选手在一场比赛中实际得分与期望得分的差距。这 440 个值即对应着随机变量  $\Delta_{B'}$  的取值，它们将会是下一小节的分析对象。

### 3.3 拟合的方法和结果

观察上一小节中获得的 440 个数值的分布情况，发现：

- 整个分布大体上对称，且以 0 为对称中心。
- 数值的分布中间稠密、两边稀疏，所有数值的绝对值都小于 0.7。
- 分布的形状类似钟形曲线。

受此启发，尝试用正态分布曲线来拟合这些数值。具体方法如下：

**步骤 1.** 对于  $t = -0.7, -0.9, \dots, 0.7$ ，计算：落在  $[t - 0.05, t + 0.05)$  中的数值个数与总个数 440 的比值。这个比值记作  $c(t)$ 。

**步骤 2.** 在平面直角坐标系中画出  $t - c(t)$  散点图。

**步骤 3.** 选取合适的参数  $\sigma > 0$ ，以使得函数

$$f(t) = \int_{t-0.05}^{t+0.05} P_{\sigma^2}(x) dx$$

的图像与这些  $t - c(t)$  数据点尽可能贴近（即残差平方和最小）。

<sup>13</sup>即信息学比赛中计算标准分的过程

<sup>14</sup>除以标准差这一步的作用也可简单理解为，消除题目区分度不同所带来的影响

这里  $P_{\sigma^2}$  表示期望值为 0、方差为  $\sigma^2$  的正态分布（用  $N(0, \sigma^2)$  表示）的概率密度函数，满足

$$P_{\sigma^2}(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{x^2}{2\sigma^2}\right)$$

再记

$$R_{\sigma^2}(t) = \int_{-\infty}^t P_{\sigma^2}(x) dx$$

为正态分布  $N(0, \sigma^2)$  的累积分布函数，则有<sup>15</sup>  $R_{\sigma^2}(t) = (1 + \operatorname{erf}(\frac{x}{\sqrt{2}\sigma}))/2$ ，其中  $\operatorname{erf}$  表示误差函数。

最后注意到

$$\int_{t-0.05}^{t+0.05} P_{\sigma^2}(x) dx = R_{\sigma^2}(t + 0.05) - R_{\sigma^2}(t - 0.05)$$

于是在进行拟合的过程中我们可以方便地计算这一定积分。




图 2: 散点图和拟合结果

图 2 展示了拟合的结果。可以看到，除了约 3 个数据点以外，其余数据点均与曲线贴合紧密。为了验证这些数据是否确实服从正态分布，还需绘制 Q-Q 图来进行检验。

图 3 展示了所绘制的 Q-Q 图。注意，该图的坐标轴经过缩放，故坐标轴上标注的数值仅能代表相对的比例关系。

<sup>15</sup> $\operatorname{erf}$  没有闭合形式，这个式子可以视为  $\operatorname{erf}$  函数的定义式




图 3: Q-Q 图，关于比赛分数差值数据和正态分布绘制

图 3 中有 440 个蓝色叉号，所有叉号的横坐标、纵坐标非严格递增。其中第  $k$  个叉号 ( $1 \leq k \leq 440$ ) 对应着 440 个数值中的第  $k$  小值  $val_k$ ，叉号的横坐标  $x_k$  等于对应的数值  $val_k$ ，而叉号的纵坐标  $y_k$  等于：440 个服从正态分布  $N(0, \sigma^2)$  的数值中，第  $k$  小值的期望；其中的  $\sigma$  是待定的参数。可以证明  $y_k$  满足  $R_{\sigma^2}(y_k) = \frac{k}{440+1}$ ，于是由这一关系可以求出  $y_k$ 。

如果这 440 个数值服从  $N(0, \sigma^2)$  的话，容易想到应该有  $x_k \approx y_k$ ，也就是说所有叉号落在直线  $y = x$  附近。我们通过选取合适的  $\sigma > 0$  来让叉号尽可能贴近直线  $y = x$ ，最终的结果就是图 3。可以看到，叉号与直线紧密贴合，所以这些数据确实服从正态分布<sup>16</sup>。又由假设 2.13，这一规律对任何 COI/IOI 赛制的比赛都成立。

**定理 3.2** (偏移量分布的形式). 对任何基于 COI 或 IOI 赛制的现实比赛，其对应的理想比赛的偏移量分布是期望值为 0 的正态分布。

## 4 选手整体水平的估计

本节将借助联赛初赛（字母标号 a）和联赛复赛（字母标号 b）的分数数据，来估计全国信息学竞赛选手整体水平的分布情况。

选手的“水平”是一个模糊的概念；为了将其量化，我们将用一名选手在联赛复赛中的期望分数来衡量这名选手的水平。

虽然由假设 2.16，不同年份的联赛复赛（所对应的理想比赛）是缩放等价的；但它们毕竟不相同，因此“在联赛复赛中的期望分数”这一概念需要澄清。4.1 小节将处理这一问题，并完成对复赛分数数据的初步分析。接着，4.2 小节将从分数数据中，得到复赛在去除了初赛的筛选所带来的影响后，其（对应的理想比赛的）分数分布函数的表达式。最后，4.3 小节将从分数分布计算出对应的期望值分布，这一分布即可体现全国选手整体水平的分布情况。

本节中会多次对现实情况作近似、作假设，于是也会不可避免地带来可观的误差。因此，本节的目标旨在估计而非精准计算，所得的结果仅能反映趋势而不保证精确。

### 4.1 复赛分数数据的获取、加工和拟合

数据来自以下 4 场比赛：

- NOIP2016 — 复赛（字母标号 b）
- NOIP2017 — 复赛（字母标号 b）
- NOIP2018 — 复赛（字母标号 b）
- CSP2019 — 复赛（字母标号 b）

<sup>16</sup>注意到，缩放坐标轴和改变  $\sigma$  的取值，这两种操作对图像的改变其实是完全相同的，所以缩放坐标轴不会影响结论的可靠性



之所以只采用 2016 年到 2019 年的比赛，是出于三个原因：

- 年代过于久远的比赛对当今的参考意义有限。
- 仅有的数据来源为 NOI 官网上的获奖名单公示，故只能取得获奖选手的分数信息。而自 2016 年起 CCF 更改了获奖规则，增加了获奖人数，使得可以获取的数据量大了许多。
- 2020 年的比赛规则有所更改（两天六题改为一天四题），所以假设 2.16 不再能保证 2020 年复赛与其他年份复赛缩放等价。

	参赛人数	获奖人数	满分	最高分	获奖分数线
NOIP2016 复赛	约 8300	约 5900	600	600	100
NOIP2017 复赛	约 10300	约 6600	600	600	80
NOIP2018 复赛	约 12900	约 8000	600	600	120
CSP2019 复赛	约 13900	约 8800	600	600	80
总计	约 45400	约 29300			

表 3: 4 场比赛的相关数据

表 3 展示了关于这 4 场比赛的几项统计数据。

由假设 2.16，这 4 场现实比赛（所对应的理想比赛）是缩放等价的。进而由命题 3.1，这 4 场现实比赛所对应的理想比赛，在对分数作变换（变换方式见 3.2 小节）后，将成为完全相同的理想比赛。

于是，与 3.2 小节类似，数据加工将按以下步骤进行：

**步骤 1.** 将所有比赛中所有选手的分数除以当场比赛的最高分（也就是计算标准分；注意到最高分等于满分），用以代替原始分数。

**步骤 2.** 去除所有  $< 0.2$  的分数。这是因为在这 4 场比赛中，获奖分数线与最高分的商的最大值为 0.2；这意味着分数低于 0.2 的选手中有一部分未能获奖，于是这些选手中其余部分的数据也失去意义，因此一并剔除。

**步骤 3.** 对每场比赛计算分数标准差  $\sigma$ ，然后对分数作变换  $R: x \mapsto 1 - \frac{1-x}{5.52\sigma}$ ，并用变换结果代替原分数。使用系数 5.52 的理由稍后说明。

**步骤 4.** 对每场比赛计算最低分，取所得的 4 个最低分的最大值  $T$ ，并剔除所有  $< T$  的分数。这一步的理由与步骤 2 中的类似：分数低于  $T$  的部分选手未能获奖，故将这些选手连同已获奖的那些一并剔除。计算可得  $T \approx 0.200$ ，与步骤 2 中的阈值保持一致；这正是系数 5.52 的主要作用。

**步骤 5.** 现在所有这些分数数据属于同一理想比赛  $A$ （满足  $A$  与原先 4 个现实比赛所对应的理想比赛缩放等价），将它们汇集起来即可。注意到我们所取得的并非完整的分数数据，而只是  $\geq 0.2$  的那一部分分数。

本节中我们约定使用理想比赛  $A$  作为衡量选手水平的标尺，也就是说我们将用一名选手在  $A$  中的期望分数，来代表该名选手的水平。后文中如果作为一个现实比赛提到“联赛

复赛”，则默认指  $A$  对应的现实比赛。

经过上述加工后，我们得到了 22093 个落在  $[0.2, 1]$  之中的分数数据。由命题 2.5，这些数据应当服从  $C_A$  所描述的概率分布。

接下来我们将确定函数  $C_A : (0, 1) \rightarrow \mathbb{R}_{\geq 0}$ ，满足在任何一个区间  $(a, b)$  上， $C_A$  的定积分在数值上约等于：分数落在  $(a, b)$  中的选手人数，与总人数 45400 的比值。

在对十余种常见函数和常见概率分布进行拟合之后，我们发现对数函数  $f(s) = -\log(s)$  满足前述要求，且与已获得数据的贴合程度大幅好于所尝试的其他函数。此外，不难验证对数函数  $f(s) = -\log(s)$  在  $(0, 1)$  上非负且定积分等于 1，因此是一个合法的分数分布函数。以下将在实际数据和据对数函数计算出的数值之间进行比对，并展示结果。

**步骤 1.** 对于  $t = 0.25, 0.35, \dots, 0.95$ ，计算：落在  $[t - 0.05, t + 0.05]$  中的分数个数与总人数 45400 的比值。这个比值记为  $c(t)$ 。

**步骤 2.** 关于  $< 0.2$  的分数段，我们不了解其中具体的分数分布，只知道这一部分共有  $45400 - 22093 = 23307$  人，占比  $\frac{23307}{45400} \approx 0.513$ 。为了与步骤 1. 中的数据统一，我们将数值 0.513 乘以

$$\frac{\int_{0.05}^{0.15} -\log(s) ds}{\int_0^{0.2} -\log(s) ds}$$

以将其换算为分数段  $(0.05, 0.15)$  上的人数占比，并记作  $c(0.1)$ 。

**步骤 3.** 在平面直角坐标系中画出  $t - c(t)$  散点图。

**步骤 4.** 检查函数

$$f(t) = \int_{t-0.05}^{t+0.05} -\log(x) dx$$

的图像是否与  $t - c(t)$  散点图吻合。

图 4 展示了比对的结果。可以看到全部数据点与曲线贴合紧密，且算得残差平方和约为  $9.2 \cdot 10^{-5}$ ，显示出了较好的拟合效果。基于此，我们确定取  $C_A(s) = -\log(s)$ 。

**命题 4.1.**  $C_A(s) = -\log(s)$ ，其中  $s \in (0, 1]$  且  $A$  是根据 4.1 小节中描述的过程所确定的理想比赛。

## 4.2 结合初赛的分析

这一小节将对于复赛所对应的理想比赛  $A$ ，在去除了初赛的筛选性所带来的影响后，计算所得的新的理想比赛（记为  $A'$ ）的分数分布函数。其中，4.2.1 小节将给出初赛分数数据的来源，4.2.2 小节将结合这些数据给出关于初赛的几个假设；第 4 节的其余部分都将依赖于这些假设。4.2.3 小节将计算初复赛（所对应理想比赛）的偏移量分布的标准差，以为 4.2.4 小节中  $C_{A'}$  的计算做好准备。




图 4: 散点图和拟合结果

### 4.2.1 初赛分数数据的获取

分数数据采用 NOIP2018 初赛北京赛区的成绩。该场比赛共 781 人获得非零分数（零分视为缺考），其中 536 人晋级复赛并获得非零分数；该场比赛满分 100 分，最高分 96 分，晋级分数线约为 35 分；全国最高分为 100 分。有关初赛的全部数据获取自官方网站上的成绩公示。

采用该场比赛的原因：后续分析需要分数表上包含选手姓名；而笔者所能找到的其他年份、其他省市的成绩公示，均未包含这一信息。

知道了选手姓名，我们就可以查询该名选手在 NOIP2018 复赛中的得分。通过这种方式，我们获得了 536 名晋级者的初赛和复赛分数。由于官方网站上的成绩公示仅包括获奖选手，这里所使用的北京选手复赛分数是按民间数据测试出的成绩。

除此以外，在 4.2.4 小节中，还将使用 CSP2019 初赛的全国分数数据，这些数据从官方网站上各省市发布的成绩公示汇总得到。CSP2019 初赛报名人数 48812 人，由于个别省份仅公示了晋级选手或未缺考选手的分数，最终收集到 47264 人的数据。

全国分数数据的来源之所以采用 CSP2019，是因为自 2019 年起才有完整的初赛分数公示。

### 4.2.2 关于初赛的几个假设

不同于复赛，信息学联赛的初赛是分省考试、分省排名的，这会给本文的分析带来很大困难。为了规避这一问题，我们作如下假设：

**假设 4.2.** 每一年的联赛初赛为全国统一考试、统一排名，全国范围内分数最高的若干名选手晋级复赛。

作出这一假设，意味着忽略不同省市间选手水平和竞争激烈程度上的差异，并用全国整体的选手水平和竞争激烈程度来代替之。即使如此，我们一般也并不能直接用一个地区的数据来“代表”全国的数据，而是只有在所研究的量与地域没有明显关联时（例如 4.2.3 小节中研究同一名选手的初赛得分与复赛得分间的关系）才能这样做。

在给出下一个假设前，先对 2018 北京初赛的分数做一点分析。

**步骤 1.** 将 536 名晋级选手按初赛分数分组：分数在  $[30, 40)$  中的、在  $[40, 50)$  中的、……、在  $[90, 100)$  中的，分别分为一组，共计 7 组。

**步骤 2.** 对每一组计算初赛平均分和复赛平均分。

**步骤 3.** 对每一组，以复赛平均分为横坐标、初赛平均分为纵坐标，将数据点画在二维平面上，并将这些数据点连成折线图。




图 5: 平均分折线图

所得的折线图如图 5 所示。可以看到，这些数据点近似地连成一条直线；这提示我们，初赛分数与复赛分数之间存在一个线性的对应关系。

基于这一观察，我们作出如下假设：

**假设 4.3.** 记现实比赛  $B_1$  为联赛初赛，取参赛人群为实际晋级复赛的全体选手；记现实比赛  $B_2$  为联赛复赛；则  $B_1, B_2$  对应的理想比赛缩放等价。

注意：“取参赛人群为实际晋级复赛的全体选手”这一规定，只限制了参赛人群，而并未要求这些选手在理想比赛中的分数也一定得达到晋级的标准。也就是说，虽然我们只取

那些在现实中达到了晋级分数线的选手，但在构造对应的理想比赛时，我们忽略现实中发生了什么，仍然只考察每名选手分数波动的概率分布和他的期望分数。

关于这一假设需要作几点说明：

1. 2.3 小节中，我们在为假设 2.16 予以辩护时，断言了“一名选手的水平是固定的，不会随比赛的改变而改变”。但是，由于考察内容的不同，一名选手在  $B_1$  和  $B_2$  中的能力差异可能较大，故上述断言在将初赛（即  $B_1$ ）加入考虑范围后似乎不再成立。

2. 为了使前述断言仍然成立，在 4.2 小节内，我们需暂时改变命题 2.3 中“期望得分”这一概念的所指，将其改为：一名选手在  $B_1, B_2$  中（在按最高分和标准差折算后）期望分数的平均值——也就是该名选手在初赛和复赛中的“综合水准”。这会改变从现实比赛构造理想比赛的方式，并使得  $B_1, B_2$  所对应理想比赛的期望值分布和偏移量分布发生变化，变化后  $B_1, B_2$  所对应的理想比赛分别记作  $F_1, F_2$ （所以  $A$  和  $F_2$  的区别，就是概念更改前和更改后的区别）。显然，此时  $F_1, F_2$  的期望值分布在经过缩放后是相同的。

3. 这样更改后， $\Delta_{B_2}$  的值也发生了变化。原先  $\Delta_{B_2}$  的取值等于选手实际表现与真实能力（即期望表现）的差；现在它的值还要在此基础上加上选手在复赛单项上的能力与初、复赛综合能力的差。但是，只要“单项能力减综合能力”这一随机变量服从正态分布，新的  $\Delta_{B_2}$  也一定服从正态分布——因为服从正态分布的独立随机变量之和依然服从正态分布。另一方面，假如在原先定义下的随机变量  $\Delta_{B_1}$  服从正态分布，则对新的  $\Delta_{B_1}$  可做与刚才类似的论证。

4. 关于  $F_1, F_2$  间的缩放等价性，第 2 条对期望值分布的缩放等价予以了说明，第 3 条对偏移量分布的缩放等价予以了说明；这些说明都有一些感性的成分，它们仅用作对假设 4.3 含义的澄清，而并非尝试对其予以证明。需要注意，由于我们对概念的修改，关于  $F_1, F_2$  的期望值分布、偏移量分布所作的一切讨论，在 4.2 小节之外均没有意义。但是  $F_1, F_2$  的分数分布不会受这一修改的影响，故 4.2 小节计算出的分数分布函数会在后续分析中直接使用。

### 4.2.3 计算偏移量分布的参数

先前已经说明，理想比赛  $F_2$  的偏移量分布为正态分布  $N(0, \sigma^2)$ 。这一小节将基于 4.2.1 小节中获得的数据，来测量该分布的标准差  $\sigma$ 。

**引理 4.4.** 独立随机变量  $X_1, X_2$  分别服从分布  $N(0, \sigma_1^2), N(0, \sigma_2^2)$ ，则  $X_1 + X_2$  服从分布  $N(0, \sigma_1^2 + \sigma_2^2)$ 。

证明见维基百科相应条目 [1]，这里不再重复。

由假设 4.3，在对  $F_1$  作线性的缩放变换  $T$  之后，可以使其与  $F_2$  相同；此时两者的偏移量分布均为  $N(0, \sigma^2)$ 。又注意到对现实比赛  $B_1, B_2$ ，其对应的随机变量  $\Delta_{B_1}, \Delta_{B_2}$  应当是独立的（这里认为在定义 2.3 的步骤 3 中  $B_1, B_2$  共用同一个表示选手的随机变量  $p$ ），所以由引

理 4.4,  $\Delta_{T[B_1]} + \Delta_{B_2}$  服从正态分布  $N(0, 2\sigma^2)$ 。因此, 选手在  $T[F_1]$  和  $F_2$  中的分数之差, 这一随机变量服从标准差为  $\sqrt{2}\sigma$  的正态分布; 只要测出它的标准差, 即可得到  $\sigma$  的取值。

容易想到以下测量方式:

**步骤 1.** 对  $F_1$  的分数作线性变换, 使得变换后它的期望值、偏移量分布与  $F_2$  相同。

**步骤 2.** 对先前提到的 536 名选手, 计算每名选手在  $F_2$  中的分数和在变换后的  $F_1$  中的分数之差。

**步骤 3.** 这 536 个差值应该服从正态分布, 那么计算这些值的标准差即可。

但一个问题是, 这 536 个差值并非真正服从正态分布。如果一名选手考出了大幅低于自己期望分数的分数, 那么他进入这 536 人之列的机会就会大大降低; 换句话说, 这 536 个数据的取样方法是有选择性的, 而且选择的方式倾向于实际分数高于期望分数的选手, 因此这些数据不能代表整体的分布。

假如我们召集那些没有晋级的选手, 让他们也参加复赛考试并记录他们的分数, 再把这些分数和原有的 536 个数据汇总, 就能获得完整、有代表性的数据。但实际上, 我们也可以“假装”已经获得了未晋级选手的数据, 并对全体数据进行分析; 如果这个过程中“碰巧”没有用到任何一个未晋级选手的数据, 我们事实上就在只凭借已有的 536 个数据的情况下完成了测量。以下给出一个这样的测量方式。

**步骤 1.** 对  $F_1$  的分数作线性变换, 使得变换后它的期望值、偏移量分布与  $F_2$  相同。

**步骤 2.** 对先前提到的 536 名选手, 计算每名选手在变换后的  $F_1$  中的分数和在  $F_2$  中的分数之差。(前者减后者)

**步骤 3.** 取出这些差值中前 35 大的值, 则这些值可以视为: 某一组服从正态分布的 781 个数 (781 即初赛参赛人数), 其中前 35 大的值。通过测量这些值可以得到正态分布的标准差。

在第 3 步中, 之所以说这 35 个值为 781 个数中的最大值, 是因为:

- 计算发现第 35 大的差值约等于 0.26, 高于初赛晋级分数线经过变换后的值。又因为复赛分数不可能小于 0, 所以任何一个未达到晋级分数线的选手, 其两试分数差值不可能达到 0.26。(计算发现 35 人中最底的初赛分数为 53 分, 比晋级分数线高出近 20 分)

- 因此, 除了 536 名晋级选手之外, 其余选手不可能进入 35 人之列, 故只考虑已有的 536 个数据是充分的。

在前述过程的步骤 1 中需要作分数变换, 以下给出具体步骤。

**步骤 1.** 对于复赛分数  $s \in [120, 600]$  (120 为官方分数公示所覆盖的最低分数), 计算该分数在全国范围内的排名  $c$ , 并将  $s$  映射到  $t \in [0, 1]$ , 满足

$$\frac{\int_t^1 -\log(x)dx}{\int_{0.186}^1 -\log(x)dx} = \frac{c}{N}$$

其中  $N = 8044$  为复赛不低于 120 分的选手总数, 0.186 为最低分数 120 依 4.1 小节中的变

换  $R$  映射到的值。

**步骤 2.** 对于低于 120 分的复赛分数，我们将  $[0, 120)$  均匀地映射到  $[0, 0.186)$  上去。以上两个步骤所描述的映射方式，保证了分数分布呈对数曲线，与命题 4.1 一致。

**步骤 3.** 计算北京初赛排名前 25% 选手（共 195 名）的分数标准差  $\sigma_1$ ，再对映射后的复赛分数计算北京选手前 195 名的分数标准差  $\sigma_2$ 。然后对于初赛分数  $s \in [0, 100]$ ，将其映射到  $1 - (1 - \frac{s}{100}) \cdot \sigma_2 / \frac{\sigma_1}{100}$ 。由命题 3.1，这一映射方式保证了映射后两个理想比赛相同。这一步中只取前 25% 的理由：对于初赛期望分数离晋级分数线较近的选手，这些选手中有相当一部分未能进入复赛，故复赛在相应分数段的分布会比真实情况稀疏；只有把考察范围限制在分数足够高的选手，才能避免这一问题。

设得到的 35 个差值按降序排列为  $d_1, \dots, d_{35}$ ，考虑如何由此推断全体差值的标准差  $\sqrt{2}\sigma$ 。

这里采用最大似然估计，即选取一个  $\sigma$  以最大化：在全体差值服从  $N(0, 2\sigma^2)$  的条件下，测量得到  $d_1, \dots, d_{35}$  的概率。注意到这个概率实际上必定等于 0，但可以通过取极限规避这一问题。下式给出  $\sigma$  的计算方式，其中  $v_k$  表示 781 个差值中的第  $k$  大值。

$$\begin{aligned}
 & \lim_{\epsilon \rightarrow 0} \arg \max_{\sigma \in \mathbb{R}_{>0}} \Pr[v_k \in [d_k - \epsilon, d_k + \epsilon], \forall 1 \leq k \leq 35] \\
 &= \lim_{\epsilon \rightarrow 0} \arg \max_{\sigma \in \mathbb{R}_{>0}} \binom{781}{35} \cdot 35! \cdot \prod_{k=1}^{35} (R_{2\sigma^2}(d_k + \epsilon) - R_{2\sigma^2}(d_k - \epsilon)) \cdot R_{2\sigma^2}(d_{35})^{746} \\
 &= \lim_{\epsilon \rightarrow 0} \arg \max_{\sigma \in \mathbb{R}_{>0}} (2\epsilon)^{-35} \cdot \prod_{k=1}^{35} (R_{2\sigma^2}(d_k + \epsilon) - R_{2\sigma^2}(d_k - \epsilon)) \cdot R_{2\sigma^2}(d_{35})^{746} \\
 &= \lim_{\epsilon \rightarrow 0} \arg \max_{\sigma \in \mathbb{R}_{>0}} \prod_{k=1}^{35} \frac{R_{2\sigma^2}(d_k + \epsilon) - R_{2\sigma^2}(d_k - \epsilon)}{2\epsilon} \cdot R_{2\sigma^2}(d_{35})^{746} \\
 &= \arg \max_{\sigma \in \mathbb{R}_{>0}} \left( \prod_{k=1}^{35} R'_{2\sigma^2}(d_k) \right) \cdot R_{2\sigma^2}(d_{35})^{746} \\
 &= \arg \max_{\sigma \in \mathbb{R}_{>0}} 746 \cdot \log(R_{2\sigma^2}(d_{35})) + \sum_{k=1}^{35} \log(P_{2\sigma^2}(d_k))
 \end{aligned}$$

至此，问题完全转化为一个最优化问题。最优化方法采用 SciPy 提供的 BFGS 算法的实现 [2]，算得  $\sigma \approx 0.109$ 。

图 6 中的橙色曲线展示了差值的概率分布，35 条蓝色竖线表示实际测得最大的 35 个差值在其中的位置。

**命题 4.5.**

$$\mathcal{D}_{T[F_1]}(\delta) = \mathcal{D}_{F_2}(\delta) = P_{\sigma_F^2}(\delta), \quad \forall \delta \in \mathbb{R}$$

其中“缩放变换” $T$  满足  $T[F_1] = F_2$ ，常数  $\sigma_F$  约等于 0.109。




图 6: 差值的分布情况

#### 4.2.4 消除初赛对分数分布的影响

这一小节将计算初赛分数线映射为复赛分数后的值，并借助该值计算出：消除初赛的筛选性带来的影响后（即假想初赛并未淘汰一人，所有选手都晋级复赛），复赛的分数的分布函数。

在 4.2.1 小节中，已经得到了 CSP2019 初赛参赛选手的分数数据。由表 3 中的数据知，在 2016 到 2019 四年中，平均每年的初赛晋级人数约为 11350；因此我们选择 CSP2019 初赛全国第 11350 名的分数，作为假设 4.2 中的“全国统一晋级分数线”。

这里之所以对晋级人数而不是晋级率取平均数，是因为初赛的参赛选手总数受收费、政策等无关因素影响过大，而晋级复赛的人数与复赛获奖的人数呈固定比例，因而相对可靠。

最终算得分数线为 63 分。作为参照，CSP2019 初赛中，浙江、山东、江苏实际的分数线<sup>17</sup>分别为 72.5, 60, 53。

下面将这一分数线映射为复赛分数。为了与 4.2.3 小节保持一致，这里仍然使用同样的计算方式，并同样采用北京的数据。

我们将计算 CSP2019 初赛中，北京排名前 195 名的分数标准差  $\sigma_1$ ，再对（按 4.2.3 小节中的方式）映射后的 NOIP2018 复赛分数计算北京选手前 195 名的分数标准差  $\sigma_2$ 。然后对于 CSP2019 初赛分数  $s \in [0, 100]$ ，将其映射到  $1 - (1 - \frac{s}{100}) \cdot \sigma_2 / \frac{\sigma_1}{100}$ 。这一计算过程基于如下假设：2019 年北京选手整体水平，与 2018 年大体相同。

<sup>17</sup>这里给出的是全省分数线，省内各市的分数线可能高于全省分数线



对分数线 63 施加上述变换, 得到其对应的复赛分数为  $h \approx 0.1035$ 。另一方面, 由命题 4.5 可知, 任何一名选手的初赛、复赛的 (变换后) 实际分数之差服从概率分布  $N(0, 2\sigma_F^2)$ 。从而, 如果假想所有初赛选手都参加了复赛, 则对于复赛实际分数为  $t$  的选手  $p$ , 其初赛分数达到 63 的概率为  $1 - R_{2\sigma_F^2}(h - t)$ 。

需要注意, 这样得到的概率, 是在获得具体的期望值分布前的先验概率。假如已知全体选手的期望分数分布情况, 我们可以用贝叶斯公式得到前述选手  $p$  的期望分数取每一个值的概率, 进而得到  $p$  的初赛分数取每一个值的概率, 也就是后验概率。简便起见这里采用先验概率, 即使它相比后验概率略失精确。

记  $F'_2$  为现实比赛  $B_2$  在消除初赛的筛选性带来的影响后所对应的理想比赛, 则由以上讨论可得:

$$C_{F'_2}(s) \propto \frac{C_{F_2}(s)}{1 - R_{2\sigma_F^2}(h - s)} = \frac{-\log(s)}{1 - R_{2\sigma_F^2}(h - s)}, \quad \forall s \in (0, 1]$$

上式中之所以使用“正比于”而不是“等于”, 是因为分数分布函数表达的是分布“密度”, 而不是样本“数量”。计算出对应的比例系数后得到:

$$C_{F'_2}(s) = \gamma \frac{-\log(s)}{1 - R_{2\sigma_F^2}(h - s)}, \quad \forall s \in (0, 1]$$

其中常数  $\gamma \approx 0.549$ , 它使得  $C_{F'_2}$  在  $[0, 1]$  上的定积分等于 1。




图 7: 消除初赛影响前后的分数分布函数

图 7 分别展示了以下三个函数的图像：

蓝色  $f(s) = -\log(s)$ ，即  $C_{F_2}(s)$  或  $C_A(s)$ 。

红色  $f(s) = \frac{-\log(s)}{1-R_{2\sigma_F^2}(h-s)}$

橙色  $f(s) = \gamma \frac{-\log(s)}{1-R_{2\sigma_F^2}(h-s)}$ ，即  $C_{F_2'}(s)$ 。

由 4.2.2 小节中的讨论知， $C_A$  与  $C_{F_2}$  相同。同理，如果定义  $A'$  为：复赛在去除初赛影响后对应的理想比赛（这里采用按原本的方式解读的定义 2.3），则  $C_{A'}$  亦与  $C_{F_2'}$  相同。因此有以下命题：

**命题 4.6.**

$$C_{A'}(s) = \gamma \frac{-\log(s)}{1-R_{2\sigma_F^2}(h-s)}, \quad \forall s \in (0, 1]$$

其中常数  $\gamma \approx 0.549$ ，且  $A'$  为复赛在去除初赛影响后对应的理想比赛。

### 4.3 从分数分布还原期望值分布

在 4.2.4 小节中得到了  $C_{A'}(s)$  的表达式；这一小节将由此计算  $\mathcal{X}_{A'}(x)$ 。

根据定理 3.2，存在  $\sigma > 0$  使得

$$\mathcal{D}_{A'}(\delta) = P_{\sigma^2}(\delta), \quad \forall \delta \in \mathbb{R}$$

进而由命题 2.10 得

$$C_{A'}(s) = \int_0^1 \mathcal{X}_{A'}(x) P_{\sigma^2}(s-x) dx, \quad \forall s \in \mathbb{R} \quad (5)$$

于是，我们可以根据(5)，由  $C_{A'}$  逆推出  $\mathcal{X}_{A'}$ 。

但是在这个问题中，期望分数接近 0 的选手占了总数中相当的比重，因此若单纯按(5)计算，则“负分数”问题（在 2.3 小节末尾有所提及）会变得十分显著。为解决这一问题，我们对于每一名选手，将其分数的概率分布中  $[0, 1]$  这一段以外的部分截掉，再将剩下的  $[0, 1]$  这一部分的概率密度函数乘以某个系数，以使得乘完后  $[0, 1]$  上的总概率为 1。若一名选手期望分数为  $x$ ，则容易证明：对该名选手而言，在上述过程中使用的系数  $c(x)$  等于

$$\left( \int_0^1 P_{\sigma^2}(t-x) dt \right)^{-1} = (R_{\sigma^2}(1-x) - R_{\sigma^2}(0-x))^{-1}$$

于是  $C_{A'}$  与  $\mathcal{X}_{A'}$  间的关系被更新为

$$C_{A'}(s) = \int_0^1 \mathcal{X}_{A'}(x) \cdot \frac{P_{\sigma^2}(s-x)}{R_{\sigma^2}(1-x) - R_{\sigma^2}(0-x)} dx, \quad \forall s \in [0, 1] \quad (6)$$

在进行逆推之前，先测量  $\sigma$  的值。我们获取了 CSP2019 复赛全体选手的民间分数（零分选手被去除，共计 12108 人获得非零分数），并按以下步骤进行测量：

**步骤 1.** 将每名选手每一天的分数除以当天最高分（两天最高分均为满分 300 分），再将每一天的所有分数做变换，以使得两天的分数分布分别呈对数曲线状。具体变换方式与 4.2.3 小节中相同；经过变换后，两天分别对应的理想比赛应当相同，且其偏移量分布应与  $\mathcal{D}_{A'}$  相同。

**步骤 2.** 对每名选手计算两天分数之差，计算所有这些差值的标准差  $\sigma_0$ 。

与 4.2.3 小节中类似，同一名选手的单日分数（变换后的分数），应该服从标准差为  $\sigma_1 = \frac{\sigma_0}{\sqrt{2}}$  的正态分布。记 CSP2019 复赛第一天、第二天，这两个现实比赛分别为  $D_1, D_2$ ，则  $\Delta_{D_1}, \Delta_{D_2}$  均服从正态分布  $N(0, \sigma_1^2) = N(0, \frac{\sigma_0^2}{2})$ 。记现实比赛  $D$  为 CSP2019 复赛（两天综合），则有  $\Delta_D = \frac{\Delta_{D_1} + \Delta_{D_2}}{2}$ 。进而由引理 4.4：

$$\begin{aligned}\text{Stddev}[\Delta_D] &= \frac{\sqrt{\text{Stddev}[\Delta_{D_1}]^2 + \text{Stddev}[\Delta_{D_2}]^2}}{2} \\ &= \frac{\sqrt{2}\sigma_1}{2} \\ &= \frac{\sigma_0}{2}\end{aligned}$$

得到  $\sigma = \frac{\sigma_0}{2}$ 。也就是说，同一名选手在 CSP2019 复赛中（变换后）的分数波动，服从标准差为  $\sigma = \frac{\sigma_0}{2}$  的正态分布。

在测出  $\sigma_0$  后，算得  $\sigma \approx 0.078$ 。


从  $C_{A'}$  和  $\mathcal{D}_{A'}$  逆推出  $\mathcal{X}_{A'}$  难以精确地实现，因此这里只能近似地计算  $\mathcal{X}_{A'}$  在许多个离散的点处的点值。

我们将区间  $(0, 1]$  作 500 等分，并设立 500 个未知数  $x_{1\dots 500}$ ，分别表示在 500 个分点处  $\mathcal{X}_{A'}$  的取值。接着，我们在(6)中将  $s$  取遍每一个分点，由此得到 500 个等式限制；注意到仅凭  $x_{1\dots 500}$  无法表示出(6)中的定积分，因此定积分被换成离散的求和。在做了这样的“离散化”之后，原先的等式显然不再严格地成立，因此改为最小化所有每一个等式两端之差的平方和。为了避免无意义的结果，我们额外加入了关于序列  $x_{1\dots 500}$  非负性和“光滑性”的限制；后者通过序列  $x_{1\dots 500}$  的高阶差分来表示。

上述问题最终归结到了一个二次规划模型的求解；可以证明其为凸二次规划，因此任何一个极值点都是最值点。最优化方法采用 SciPy 提供的信赖域算法的实现 [2]。用于计算的程序和最终算得的点值  $x_{1\dots 500}$ ，可以在本文开头的链接中找到。

观察所得的 500 个点值，发现：

1. 在与 0 紧邻的位置处，点值明显大于其他位置。
2. 在其余位置处，点值构成一条平滑的曲线。计算发现这些点值近似地符合二次函数  $f(x) = ax^2 + bx + c$ ，其中  $a \approx 1.697, b \approx -3.352, c \approx 1.655$ 。图 8 展示了该函数的图像。

图 8: 二次函数  $f(x) = ax^2 + bx + c$ 

至此，我们得到了函数  $X_{A'}$  的表达式。

**定理 4.7.** 对于  $x \in (\epsilon, 1]$  有  $X_{A'}(x) = ax^2 + bx + c$ ，其中  $a \approx 1.697, b \approx -3.352, c \approx 1.655$ ， $\epsilon$  为某个小常数， $A'$  为复赛在去除初赛影响后对应的理想比赛。

最后，如本节开头所说，本节的目标旨在估计而非精准计算，所得的结果仅能反映趋势而不保证精确；这对上述定理也同样成立。

## 5 关于比赛名次的讨论

本节中研究关于比赛名次的性质，这些性质可以为选手的比赛策略制订和日常训练导向提供参考。

### 5.1 比赛名次与实际水平的关系

一名选手在比赛得分上的波动，导致了他在比赛名次上的波动。考虑到各种奖项的颁发都是以名次而非得分为主要依据，研究选手比赛名次的概率分布就显得格外重要。

具体地说，对于  $A, B$  为一对互相对应的理想比赛和现实比赛，在这一小节中我们考虑：在该场比赛中额外加入一名选手  $p$ （该选手得分的概率分布给定），则他的名次的概率分布为何。特别地，我们研究两个自变量（选手  $p$  的期望分数和分数波动幅度）对两个因变量（选手  $p$  的期望名次和中位名次）的影响。

本节中考虑的  $B$  均为 COI/IOI 赛制的信息学比赛。于是由定理 3.2,  $\Delta_B$  和选手  $p$  的得分都服从正态分布。

### 5.1.1 期望分数与比赛名次的关系

记随机变量  $C_p$  为  $p$  的（与  $B$  中的选手分数一起，按定义 2.3 中的方式变换过后的）分数，设其服从期望值为  $\mu$ 、标准差为  $\sigma$  的正态分布，并用  $\mathcal{D}_p$  来表示  $C_p - \mu$  的概率密度函数。

令随机变量  $U_p$  表示： $B$  中有多大比例的选手实际得分高于  $p$  的实际得分（例如  $U_p = 0.5$  表示  $B$  中恰一半的选手实际得分高于  $p$ ）。

令实数  $V_p$  表示： $B$  中有多大比例的选手期望得分高于  $p$  的期望得分（例如  $V_p = 0.5$  表示  $B$  中恰一半的选手期望得分高于  $p$ ）。

此外设  $\Delta_B$  服从正态分布  $N(0, \sigma_B^2)$ ，从而对任意  $\delta$  有  $\mathcal{D}_A(\delta) = P_{\sigma_B^2}(\delta)$ 。

这一小节中将对变化的  $\mu$ ，考察以下两个量的变化趋势：

- $D_1 = E[U_p] - V_p$
- $D_2 = \text{Med}[U_p] - V_p$ ，其中中位名次  $\text{Med}[U_p]$  满足  $\Pr[U_p > \text{Med}[U_p]] = 0.5$

对于  $E[U_p]$  不难发现：

$$\begin{aligned}
 E[U_p] &= \int_0^1 \mathcal{X}_A(x) \left( \iint_{\{(\delta_1, \delta_2) : \mu + \delta_1 \leq x + \delta_2\}} \mathcal{D}_p(\delta_1) \mathcal{D}_A(\delta_2) d(\delta_1, \delta_2) \right) dx \\
 &= \int_0^1 \mathcal{X}_A(x) \left( \iint_{\{(\delta_1, \delta_2^-) : \delta_1 + \delta_2^- \leq x - \mu\}} P_{\sigma^2}(\delta_1) P_{\sigma_B^2}(-\delta_2^-) d(\delta_1, \delta_2^-) \right) dx \\
 &= \int_0^1 \mathcal{X}_A(x) \left( \int_{-\infty}^{x-\mu} P_{\sigma^2 + \sigma_B^2}(\delta) d\delta \right) dx \\
 &= \int_0^1 \mathcal{X}_A(x) R_{\sigma^2 + \sigma_B^2}(x - \mu) dx
 \end{aligned}$$

而对于  $\text{Med}[U_p]$  有

$$\begin{aligned}
 \text{Med}[U_p] &= \int_{\mu}^{+\infty} C_A(s) ds \\
 &= \int_0^1 \mathcal{X}_A(x) R_{\sigma_B^2}(x - \mu) dx
 \end{aligned} \tag{7}$$

其中等式(7)成立的理由是

$$\begin{aligned} & \Pr \left[ U_p > \int_{\mu}^{+\infty} C_A(s) ds \right] \\ &= \Pr [C_p < \mu] \\ &= 0.5 \end{aligned}$$

由此可以对给定的  $\mu, \sigma, \mathcal{X}_A, \sigma_B$  计算  $D_1, D_2$  的值。




图 9:  $D_1, D_2$  的图像, 当  $A$  为定理 4.7 中的  $A'$  时

取理想比赛  $A$  为定理 4.7 中“复赛在去除初赛影响后对应的理想比赛” $A'$ 、取  $\sigma = \sigma_B \approx 0.078$  (该数值来自于 4.3 小节中的测量), 则  $D_1, D_2$  关于  $\mu$  的图像如图 9。这里对于期望分数小于 (定理 4.7 中的)  $\epsilon$  的选手, 将他们从  $\mathcal{X}_A$  中剔除, 并将  $\mathcal{X}_A$  剩余部分的点值乘上某个系数, 以使得其在  $[0, 1]$  上定积分仍为 1。这样得到的  $\mathcal{X}_A$  为二次函数。此外,  $D_1, D_2$  本身是“绝对差值”, 图中还用虚线绘制了“相对差值”  $\frac{D_1}{E[U_p]}, \frac{D_2}{\text{Med}[U_p]}$  的图像。

图 9 所考虑的情况是: 现实比赛  $B$  的参赛人群为期望分数达到  $\epsilon$  的全体信息学选手。但是对于实际中的比赛, 其参赛选手往往是经过选拔的; 以下将研究此类比赛。

简便起见, 我们作如下假设: 现实比赛  $B$  的参赛人群, 是期望分数达到  $\epsilon$  的全体信息学选手, 经过一场现实比赛  $C$  的选拔后达到分数线的那些; 其中  $C$  所对应的理想比赛与去除低水平选手 (即期望分数  $< \epsilon$  的选手) 后的  $A'$  相同, 且分数线为  $\text{thres} \in [0, 1]$ 。




图 10:  $D_1, D_2$  的图像, 当 A 对应联赛复赛时




图 11:  $D_1, D_2$  的图像, 当 A 对应 NOI 时

由此易知，对于一名期望分数为  $\mu_q \in [0, 1]$  的选手  $q$ ，他达到分数线的概率为  $1 - R_{(0.078)^2}(thres - \mu_q)$ 。进而得到：

$$\chi_A(x) \propto (ax^2 + bx + c)(1 - R_{(0.078)^2}(thres - x)), \quad \forall x \in [0, 1]$$

其中  $a, b, c$  为定理 4.7 中的系数。

为模拟联赛复赛的情况，取  $thres = 0.1053$ （该数值为 4.2.4 小节中的计算结果），此时  $D_1, D_2$  的图像如图 10；为模拟 NOI 的情况，取  $thres = 0.7$ （计算发现近几年联赛中得分高于该数值的选手人数与 NOI 的参赛人数相近，故选择该数值），此时  $D_1, D_2$  的图像如图 11。

观察图 9、图 10 和图 11，可以得到以下结论：

在一场信息学比赛中，对任何一名期望得分“不太低”的选手，他的期望名次、中位名次，均差于他的实际水平（以期望得分来衡量）在全体参赛选手中的位次。这一现象随着该名选手期望得分的升高而越发明显，在高分段尤其显著。

这一点也很容易直观理解：分数分布大体上呈现“低分稠密、高分稀疏”的特点，所以期望得分接近但低于  $p$  的选手数量，大于期望得分接近且高于  $p$  的选手数量。进而，将  $p$  反超的人数，就会大于被  $p$  反超的人数。

### 5.1.2 分数波动幅度与比赛名次的关系

这一小节中将考察  $\sigma$  的变化对  $E[U_p]$  的影响。注意到  $\sigma$  的变化不影响  $\text{Med}[U_p]$  的值，所以这里不考虑  $\text{Med}[U_p]$ 。

记  $E[U_p](\mu_0, \sigma_0)$  为  $\mu = \mu_0, \sigma = \sigma_0$  时  $E[U_p]$  的取值，则我们将考察以下函数：

$$F(\mu_0, \sigma_0) = \frac{E[U_p](\mu_0, \sigma_0) - E[U_p](\mu_0, 0)}{E[U_p](\mu_0, \sigma_0) + E[U_p](\mu_0, 0)}$$

函数  $F$  的含义是  $E[U_p]$  随  $\sigma$  的变化而产生的增量；这里的增量用  $E[U_p](\mu_0, \sigma_0)$  与  $E[U_p](\mu_0, 0)$  的相对差值来描述，由于二者中任何一者都可能远小于对方，故分母上取二者之和而非二者之一。

上一小节中对三个比赛分别绘制了  $D_1, D_2$  的图像；这里我们对同样的三个比赛绘制  $F$  的图像，见图 12、图 13 和图 14。图中底部的线条为上方曲面的等高线。此外请注意图中坐标轴的方向。

观察三个图像，可以得到以下结论：






图 12:  $F$  的图像, 当  $A$  为定理 4.7 中的  $A'$  时




图 13:  $F$  的图像，当  $A$  对应联赛复赛时




图 14:  $F$  的图像，当  $A$  对应 NOI 时

在一场信息学比赛中，对任何一名期望得分“不太低”的选手，若他的期望得分固定，则当他的分数分布的标准差提高时，他的期望名次变差。这一现象随着该名选手期望得分的升高而越发明显，在高分段尤其显著。

## 5.2 多日比赛总名次与单日名次的关系

大多数信息学比赛都包括两天或更多的比赛日，而对于其中的大部分比赛，选手在每日比赛后也都能直接或间接地知道自己当日的大致排名。这种情况下，一名选手在先前的比赛日中的排名，对他在之后的比赛日中的策略制定是一个重要信息。要想有效利用这一信息，首先需要了解多日比赛总名次与单日名次之间的关系，这正是本小节的目标。

先给出这一小节用到的模型：现实比赛  $B_{1\dots k}$  分别表示每一天的比赛，它们对应同一个理想比赛  $A$ 。一名选手的总分定义为：他在  $B_{1\dots k}$  中的分数  $score_{1\dots k}$ （满足  $score_i \in [0, 1]$ ）的加权平均数  $w_1 score_1 + \dots + w_k score_k$ （满足  $w_1 + \dots + w_k = 1$ ）。

在实际中，每天的比赛在难度、区分度上可能有差异，因此仅可以认为各天的比赛（所对应的理想比赛）缩放等价而不是完全相同；但通过引入权值  $w_{1\dots k}$ ，可以将这些比赛“标准化”。也就是说， $w_{1\dots k}$  在此处相当于“缩放系数”，与等价映射中的一次项系数作用相同。

设  $\Delta_{B_i}$  服从正态分布  $N(0, \sigma_B^2)$ 。以下我们关注比赛中的一名特定选手  $p$ ，记他各天的分数为  $score_{1\dots k}$ 、各天的名次为  $rank_{1\dots k}$ （满足  $rank_i \in [0, 1]$ ，定义方式与上一节中的  $U_p$  相同），我们将尝试从  $rank_{1\dots k}$  近似地计算  $p$  的总分名次  $rank_{total} \in [0, 1]$ 。

这里我们还要求：

- $\mathcal{X}_A(x) = (a'x^2 + b'x + c')(1 - R_{\sigma_p^2}(thres - x))$ ，其中  $(a', b', c') \propto (a, b, c)$  为常系数、 $thres, \sigma_p$  为某两个不关心其具体取值的常数。

- 注意到对足够大的  $x$ （不妨划定为  $x \geq T$ ，其中  $T$  为某个不关心其具体取值的常数）有  $\mathcal{X}_A(x) \approx a'x^2 + b'x + c'$ 。我们要求  $p$  的得分和名次足够高，以致于  $\mathcal{X}_A(x)$  在  $x < T$  的部分对答案几乎没有影响。

### 5.2.1 $\sigma_B = 0$ 的情况

在这一小节中，假设  $\sigma_B = 0$ 。严格地说， $\sigma_B$  必须是正数，否则  $N(0, \sigma_B^2)$  就并非良定义；但这里  $\sigma_B = 0$  仅用来表达  $C_A = \mathcal{X}_A$ ，故暂且忽略这一问题。

通过对系数  $a', b', c'$  的计算, 发现  $a'x^2 + b'x + c' \approx a'(x-1)^2$ , 于是可以得到:

$$\begin{aligned} rank_i &= \int_{score_i}^1 C_A(s) ds \\ &\approx \int_0^{1-score_i} a' s^2 ds \\ &= \frac{a' (1 - score_i)^3}{3} \end{aligned}$$

所以有

$$1 - score_i \approx \sqrt[3]{\frac{3rank_i}{a'}}$$

进而  $p$  的总分  $score_{total}$  满足

$$1 - score_{total} \approx \sum_{i=1}^k w_i \sqrt[3]{\frac{3rank_i}{a'}}$$

最后

$$\begin{aligned} rank_{total} &\approx \frac{a' (1 - score_{total})^3}{3} \\ &\approx \frac{a'}{3} \cdot \left( \sum_{i=1}^k w_i \sqrt[3]{\frac{3rank_i}{a'}} \right)^3 \\ &= \left( \sum_{i=1}^k w_i \sqrt[3]{rank_i} \right)^3 \end{aligned}$$

注意到上式的左右两边是齐次的, 所以, 若将所有  $rank_{1\dots k}$  和  $rank_{total}$  同时乘以常数, 则正确性不会受影响。因此即使取  $rank_{1\dots k}$  和  $rank_{total}$  为“原始排名”(即分数高于  $p$  的人数), 上式仍然成立。

得到结论:

若忽略参赛选手分数的波动(也就是假设, 除  $p$  以外的任何选手在任何一天中都恰会考出自己的期望得分), 则对于得分足够高的选手  $p$ , 其总名次约等于每日名次的  $1/3$  次加权幂平均。

结合幂平均不等式 [3], 可以得到如下推论:

在上一结论的条件下, 选手  $p$  的总名次一定不差于 (即数值上不大于) 每日名次的加权平均数, 取等仅当每日名次相同。更进一步, 在名次加权平均数固定的情况下, 名次波动幅度越大, 总名次一般越好 (即数值上越小); 换句话说, 对单场比赛而言, 前进  $n$  名对总名次的正面影响, 一般大于后退  $n$  名对总名次的负面影响。

### 5.2.2 $\sigma_B > 0$ 的情况

这一小节中考虑  $\sigma_B > 0$  的情况。

首先, 为了能够直接确定系数  $a', b', c'$ , 我们不妨取  $thres$  为  $-\infty$ , 也就是说对任何  $x \in [0, 1]$  有  $X_A(x) = a'x^2 + b'x + c'$ 。注意到对于  $X_A(x)$  在  $x \in [T, 1]$  的部分而言,  $thres$  的变化只相当于对这一部分函数值做等比例缩放; 而稍后会看到, 对  $X$  和  $C$  的函数值的等比例缩放, 不会影响后续推导的正确性。因此, 钦定  $thres$  的取值不会影响一般性。

为了使得后续推导成为可能, 需要先对函数  $C_A$  作近似, 以简化其形式。

对于确定的  $\sigma_B$ , 可以计算得到实数  $r(\sigma_B) \geq 1$  和  $a(\sigma_B) \geq 0$ , 以使得函数  $f_{\sigma_B}(s) = a(\sigma_B)(r(\sigma_B) - s)^2$  的图像与  $C_A$  尽可能贴近 (即残差平方和最小)。实验发现:

$$\max_{\sigma_B \in (0, 0.4], s \in [0.6, 1]} |f_{\sigma_B}(s) - C_A(s)| \approx 0.02$$

由此可见, 这一近似的效果十分优秀。


回忆到我们只关注“足够高”的那一部分分数分布, 因此在上式中仅考虑  $s \geq 0.6$ 。在实际中  $\sigma_B$  不可能高于 0.4, 所以这里也只考虑  $\sigma_B \in (0, 0.4]$ 。

图 15 展示了函数  $a(\sigma)$  和  $r(\sigma)$  的图像。可以看到, 前者大体上递降, 而后者则递增。

将全部  $k$  个比赛合并视为一个现实比赛  $B_{total}$ , 以下计算 (服从正态分布的) 随机变量  $\Delta_{B_{total}}$  的标准差  $\sigma_{total}$ 。

$$\begin{aligned} \sigma_{total} &= \text{Stddev} \left[ \sum_{i=1}^k w_i \Delta_{B_i} \right] \\ &= \sqrt{\sum_{i=1}^k \text{Stddev} [w_i \Delta_{B_i}]^2} \\ &= \sqrt{\sum_{i=1}^k w_i^2 \sigma_B^2} \\ &= \sqrt{\sum_{i=1}^k w_i^2} \cdot \sigma_B \end{aligned}$$

特别地, 当权重  $w_i$  全部相等时,  $\sigma_{total} = k^{-1/2} \sigma_B$ 。

图 15: 函数  $a(\sigma)$  和  $r(\sigma)$  的图像

接下来类比上一小节进行推导。注意到  $C_A(s)$  在  $s \in (1, r]$  的部分也要纳入考虑。

$$\begin{aligned}
 rank_i &= \int_{score_i}^{r(\sigma_B)} C_A(s) ds \\
 &\approx \int_0^{r(\sigma_B) - score_i} a(\sigma_B) s^2 ds \\
 &= \frac{a(\sigma_B) (r(\sigma_B) - score_i)^3}{3}
 \end{aligned}$$

$$\begin{aligned}
 r(\sigma_B) - score_{total} &= \sum_{i=1}^k w_i (r(\sigma_B) - score_i) \\
 &\approx \sum_{i=1}^k w_i^3 \sqrt{\frac{3 rank_i}{a(\sigma_B)}}
 \end{aligned}$$

$$\begin{aligned}
rank_{total} &\approx \frac{a(\sigma_{total})(r(\sigma_{total}) - score_{total})^3}{3} \\
&\approx \frac{a(\sigma_{total})}{3} \cdot \left( r(\sigma_{total}) - r(\sigma_B) + \sum_{i=1}^k w_i \sqrt[3]{\frac{3rank_i}{a(\sigma_B)}} \right)^3 \\
&= \frac{a(\sigma_{total})(r(\sigma_{total}) - r(\sigma_B))}{3} + \frac{a(\sigma_{total})}{a(\sigma_B)} \left( \sum_{i=1}^k w_i \sqrt[3]{rank_i} \right)^3
\end{aligned}$$

发现总名次  $rank_{total}$  是关于  $(\sum_{i=1}^k w_i \sqrt[3]{rank_i})^3$  的一次函数。接着注意到  $\sigma_{total} < \sigma_B$ ，故由  $a(\sigma), r(\sigma)$  的增减性可知，该一次函数的一次项系数大于等于 1，而常数项小于等于 0；因此自变量和因变量的大小关系无法直接确定。




图 16: 一次函数的系数，以及大小关系改变的阈值

图 16 展示了以下 4 个量关于  $\sigma_B$  的图像：

**蓝色** 在典型情况下（指的是  $k = 2, w_1 = w_2$  时的情况，此时  $\sigma_{total} = 2^{-1/2}\sigma_B$ ）的一次项系数  $K = a(\sigma_{total})/a(\sigma_B)$ 。

**红色** 在典型情况下的常数项  $B = a(\sigma_{total})(r(\sigma_{total}) - r(\sigma_B))/3$ 。

**黄色** 最大的  $m \in [0, 1]$  满足在典型情况下有  $Km + B \leq m$ 。

**绿色** 最大的  $m \in [0, 1]$  满足在任何情况下（对  $\sigma_{total}$  只需符合  $\sigma_{total} < \sigma_B$  即可）都有  $Km + B \leq m$ 。



观察到绿色曲线的纵坐标始终不低于 0.2，因此可以认为

$$\left[ \left( \sum_{i=1}^k w_i \sqrt[3]{rank_i} \right)^3 \leq 0.2 \right] \Rightarrow \left[ rank_{total} \leq \left( \sum_{i=1}^k w_i \sqrt[3]{rank_i} \right)^3 \right]$$

回忆到先前要求  $p$  的得分“足够高”，因此我们不考虑  $\left( \sum_{i=1}^k w_i \sqrt[3]{rank_i} \right)^3 > 0.2$  的情况。

在本小节的开头，我们作了  $thres = -\infty$  的假设。注意到随着  $thres$  的升高，所有  $a(\sigma)$  会等比例地变大，而  $r(\sigma)$  不变，进而可以证明阈值 0.2 只会变大而不会变小。因此，我们所考虑的  $thres = -\infty$  恰好是最坏情况。

最终得到结论：

对于得分足够高的选手  $p$ ，计算其每日名次的  $1/3$  次加权幂平均  $m$ ，则  $p$  的总名次  $M$  近似地满足线性关系  $M = K \cdot m + B$ ，其中系数  $K, B$  由比赛本身确定。如果  $p$  的排名在前 20%（即  $m \leq 0.2$ ），则进一步有  $M \leq m$ 。

从上述性质可以导出一个有趣的推论：如果  $p$  的每日名次都相等且在前 20%，则  $p$  的总名次一定不差于他的每日名次。

## 6 关于分级选拔的讨论

“分级选拔”是一种选拔优秀选手的方式。在这种方式中，选手要经过一系列逐级递进的比赛，在每场比赛中会淘汰排名最低的一部分选手，其中排名的依据是选手在已经完成的所有比赛中的得分加权和。在信息学竞赛省队和国家队的选拔中，都用到了分级选拔的方式，例如部分省市往年的省队选拔所采用的“联赛—省选一轮—省选二轮”三级选拔，还有往年国家队选拔所采用的“CTT—冬令营—CTSC”三级选拔。本节中将探讨的是，如何设置分级选拔的流程以改善选拔效果。

先给出描述分级选拔的模型：

- $B_{1 \dots n}$  为（基于 COI/IOI 赛制的）信息学比赛，它们依次表示  $n$  级选拔中的每一级比赛。 $A_{1 \dots n}$  为  $B_{1 \dots n}$  所对应的理想比赛。
- 权重  $w_{1 \dots n}$  为正实数，分数线  $h_{1 \dots n}$  为正实数。
- 对于  $B_i$  的参赛人群中的一名选手  $p$ ，记  $score_j(p)$  表示  $p$  在  $B_j$  ( $j \leq i$ ) 中的得分，按定义 2.3 中的方式（即把原始分数除以最高分）折算后的值。再定义  $p$  的前  $i$  轮总分为

$$\frac{w_1 score_1(p) + \dots + w_i score_i(p)}{w_1 + \dots + w_i}$$

- $B_1$  的参赛人群可任意指定，称为初始人群。

• 对于  $i > 1$ ,  $B_i$  的参赛人群可按如下方式确定: 取  $B_{i-1}$  的参赛人群, 再去除那些前  $i-1$  轮总分低于  $h_{i-1}$  的选手。

•  $B_n$  的参赛人群中, 前  $n$  轮总分达到  $h_n$  的选手视为通过选拔, 这一人群称为**获胜人群**。获胜人群大小与初始人群大小的比值, 称为**选拔比例**。

## 6.1 分级选拔权重的设置

这一小节将计算最优的权重  $w_1, \dots, w_n$ 。若将淘汰的过程纳入考虑, 则不同轮次的比赛之间会产生复杂的相互影响, 因此为简便起见, 这一小节中将假设  $h_1 = h_2 = \dots = h_{n-1} = 0$ , 即前  $n-1$  轮都不会淘汰任何选手。

由定理 3.2 知: 存在正实数  $\sigma_1, \dots, \sigma_n$ , 满足每一个  $\Delta_{B_i}$  都服从正态分布  $N(0, \sigma_i^2)$ 。进而由引理 4.4, 任何一名选手  $p$  的前  $n$  轮总分都服从正态分布, 且其标准差  $\bar{\sigma}_n$  满足:

$$\begin{aligned}\bar{\sigma}_n &= \text{Stddev} \left[ \frac{w_1 \text{score}_1(p) + \dots + w_n \text{score}_n(p)}{w_1 + \dots + w_n} \right] \\ &= \text{Stddev} \left[ \frac{w_1 \Delta_1 + \dots + w_n \Delta_n}{w_1 + \dots + w_n} \right] \\ &= \sqrt{\frac{w_1^2 \sigma_1^2 + \dots + w_n^2 \sigma_n^2}{(w_1 + \dots + w_n)^2}}\end{aligned}$$

容易想到, 选手的前  $n$  轮总分波动幅度越大, 关于这一总分的排名也就越不可靠。因此, 我们希望  $\bar{\sigma}_n$  尽可能小。

**引理 6.1** (柯西不等式). 对任何正实数  $a_1, \dots, a_n$  和  $b_1, \dots, b_n$ , 一定有

$$\left( \sum_{i=1}^n a_i^2 \right) \left( \sum_{i=1}^n b_i^2 \right) \geq \left( \sum_{i=1}^n a_i b_i \right)^2$$

上式当且仅当  $\frac{b_1}{a_1} = \dots = \frac{b_n}{a_n}$  时取等。

在上述引理中取  $a_i = \sigma_i^{-1}, b_i = w_i \sigma_i$ :

$$\begin{aligned}\left( \sum_{i=1}^n \sigma_i^{-2} \right) \left( \sum_{i=1}^n w_i^2 \sigma_i^2 \right) &\geq \left( \sum_{i=1}^n w_i \right)^2 \\ \frac{\sum_{i=1}^n w_i^2 \sigma_i^2}{\left( \sum_{i=1}^n w_i \right)^2} &\geq \left( \sum_{i=1}^n \sigma_i^{-2} \right)^{-1}\end{aligned}$$

由此得到: 对于固定的  $\sigma_1, \dots, \sigma_n$ , 当  $w_1, \dots, w_n$  满足  $w_1 \sigma_1^2 = \dots = w_n \sigma_n^2$  (也就是  $w_i \propto \sigma_i^{-2}$ ) 时,  $\bar{\sigma}_n$  取到最小值  $(\sum_{i=1}^n \sigma_i^{-2})^{-1/2}$ 。

此外,  $w_1\sigma_1^2 = \cdots = w_n\sigma_n^2$  这一条件也显然能够保证: 对任何一个  $i$ , 选手  $p$  的前  $i$  轮总分的标准差最小。

于是得到结论:

分级选拔中一场比赛的权重, 应当与该场比赛偏移量分布的方差 (即标准差的平方) 成反比。此时对任何一名选手, 其前  $i$  轮总分 (总分视为一个随机变量) 的标准差, 等于前  $i$  场比赛的偏移量分布标准差的  $-2$  次幂平均。

## 6.2 三级选拔分数线的划定

这一小节将对于一个特殊的分级选拔模型计算出合适的分数线, 以使得选拔效果最好。之所以只考虑特殊情形, 是因为这一小节旨在演示计算方法; 但是, 计算结果也同时对更一般的情形有参考价值。

这一小节中将考察满足以下条件的分级选拔模型:

- $n = 3$ , 即所考察的是三级选拔的模型。
- $\Delta_{B_1}, \Delta_{B_2}, \Delta_{B_3}$  都服从正态分布  $N(0, \sigma^2)$ , 其中  $\sigma \approx 0.078$  为 4.3 小节中对于联赛复赛计算得到的数值。
- $w_1 = w_2 = w_3$ , 即三场比赛等权。
- $X_{A_1} \propto ax^2 + bx + c$  ( $x \in [0, 1]$ ), 其中  $a, b, c$  为定理 4.7 中给出的数值。比例系数可根据 “ $X_{A_1}$  在  $[0, 1]$  上的定积分为 1” 这一性质确定。
- 对任何一名选手  $p$ ,  $p$  在  $B_1, B_2, B_3$  中的期望得分 (在按定义 2.3 中的方式折算后) 相同。
- 选拔比例为 0.1。

对上述规定可以作这样的直观理解: 一个三级选拔的模型, 每一级的比赛都类似于联赛复赛, 而初始人群是期望得分高于  $\epsilon$  (定理 4.7 中的小常数) 的全体信息学选手。

目标函数和限制条件:

- 用获胜人群中所有选手 (在  $B_1$  或  $B_2$  或  $B_3$  中的) 期望得分的平均值  $\bar{X}$  来衡量选拔效果。我们希望最大化  $\bar{X}$ 。
- 将  $B_1$  的参赛人群大小定为单位 “1”, 则用  $B_1, B_2, B_3$  参赛人群的总大小  $S$  来衡量整场选拔的开销; 这个 “开销” 既包括主办方的组织成本, 也包括参赛选手的时间成本。我们要求开销  $S$  不超过上限  $T$ , 其中参数  $T$  满足  $T > 1.2$ 。(注意到  $B_2, B_3$  的参赛人群大小不可能低于选拔比例 0.1, 所以  $T$  不可能低于 1.2)

容易发现, 只要再给定分数线  $h_1, h_2, h_3$ , 就能唯一确定  $A_1, A_2, A_3$  的期望值分布、分数分布等信息。又注意到, 如果  $h_1, h_2$  的取值给定, 我们可以根据 “选拔比例为 0.1” 这一信

息确定  $h_3$ 。所以，我们实际上需要求解的是  $h_1, h_2$  的最佳取值。

先考虑如何在给定  $h_1, h_2, h_3$  的情况下（暂时忽略选拔比例为 0.1 的要求），计算  $\bar{X}$  和  $S$ 。只要能够计算出  $P(x)$  表示一名（在  $B_1, B_2, B_3$  中）期望得分为  $x$  的选手通过选拔的概率，就可以对函数  $f(x) = P(x) \cdot \chi_{A_1}(x)$  做数值积分来算出选拔比例，然后对函数  $g(x) = x \cdot f(x)$  做数值积分再除以选拔比例来得到  $\bar{X}$ ，而  $S$  也可以类似地计算。

$P(x)$  的计算将按照如下步骤进行：（用  $p$  来代表随意选取的一名期望得分为  $x$  的选手）

**步骤 1.** 将数轴正半轴以  $1/256$  为单位划分成小格，并对  $[0, 1]$  这一数轴区间内的每个小格，计算一场比赛中选手  $p$  的实际得分落在该小格内的概率。这一概率的表达式可以类比 4.3 小节中的(6)式。记所得的 256 个概率数值构成序列  $D$ 。以下将近似地认为， $D$  所表示的概率在同一个格中均匀分布。

**步骤 2.** 维护长为  $3 \times 256 = 768$  的序列  $C$ ，其中  $C_i$  表示选手  $p$  晋级到当前轮次且当前所有轮次的得分总和落在第  $i$  个小格中的概率。初始时仅考虑第一轮（即  $B_1$ ），此时  $C$  在  $[0, 1]$  这一数轴区间内的每一个概率数值都和  $D$  相同，而在  $(1, 3]$  内的每一个概率数值都等于 0。以下将近似地认为， $C$  所表示的概率在同一个格中均匀分布。

**步骤 3.** 将  $B_2$  纳入考虑。具体地说，先将  $C$  在  $[0, 1 \times h_1)$  这一数轴区间内的概率数值都清零（表示淘汰掉低于分数线的选手），再将其与  $D$  做类似卷积的运算（表示将选手  $p$  在  $B_2$  中的得分加入  $p$  的总分），所得的结果即为新的  $C$ 。

**步骤 4.** 将  $B_3$  纳入考虑。具体地说，先将  $C$  在  $[0, 2 \times h_2)$ （ $h_2$  是按均分划定的分数线， $2 \times h_2$  是按总分划定的分数线）这一数轴区间内的概率数值都清零，再将其与  $D$  做类似卷积的运算，所得的结果即为新的  $C$ 。

**步骤 5.** 计算  $C$  在数轴区间  $[3 \times h_3, 3]$  内的概率数值之和，所得结果即为  $P(x)$ 。

以上描述了从  $h_1, h_2, h_3$  计算  $\bar{X}, S$  和选拔比例的方法。如果仅给定  $h_1, h_2$ ，则可以通过二分法等数值求根方法计算出合适的  $h_3$  以使得选拔比例恰为 0.1。

至此，我们已经能够高效计算待优化的函数。

我们令参数  $T$  分别取值 1.3, 1.4,  $\dots$ , 2.0，并对于这之中的每一种取值，使用 SciPy 中实现的差分进化算法 [4] 计算出了  $h_1, h_2$  的最优取值和与之对应的  $h_3$  的取值。其中对于优化效果不理想的，进行了多次运行取最优的操作。计算结果和用于计算的程序，可以在本文开头的链接中找到。

在图 17 中，上图展示了所得的每一个最优解中  $h_1, h_2, h_3$  的取值，下图展示了每一个最优解中分别在  $B_1, B_2, B_3$  达到分数线的人数（以初始人群大小为单位“1”）。两张图的横轴均表示所得的解的实际开销而非开销上限；由于最优化的过程中存在误差，实际开销并不一定紧贴开销上限。

下面以  $T = 2.0$  时的解为例，展示所得选拔过程的选拔效果，见图 18。对于  $T$  的其他取值所绘制的相应图像与图 18 十分接近，故这里仅展示  $T = 2.0$  时的结果。




图 17: 在开销上限的不同取值下，最优解中每一轮次的分数线和人数




图 18:  $T = 2.0$  时的最优解中,  $P(x), \chi_{A_1}(x), P(x) \cdot \chi_{A_1}(x)$  关于  $x$  的图像

## 7 总结

本文建立了描述信息学比赛的数学模型（第 2 节），并基于该模型作出了以下几个发现：

- 同一名选手的得分波动服从正态分布（第 3 节）
- 联赛复赛的分数分布符合对数曲线（4.1 小节）
- 全国信息学选手的水平分布情况大致符合二次曲线（4.3 小节）
- 一名选手按真实水平排序的名次，与该选手在实际比赛中的期望名次、中位名次之间存在特定的关系，且很多时候后两者差于前者（5.1 小节）
- 在多日比赛中，每日名次与总名次之间存在特定的关系（5.2 小节）
- 在分级选拔中，可以按一定方法设置各级比赛的权重和分数线，以使得选拔效果最好（第 6 节）

本文只对信息学竞赛的少数几个方面进行了探究，而即使对于本文着力研究的几个问题，所采用的研究方法在其可靠性、精确性上也有很大改进空间。希望本文能起到抛砖引玉的作用，吸引更多感兴趣的读者来研究有关信息学竞赛本身的问题。

## 8 致谢

感谢中国计算机学会提供交流和学习的平台；  
感谢国家集训队高闻远教练的指导；  
感谢家人对我的支持和关爱；  
感谢老师、教练们对我的培养；  
感谢清芷等同学与我讨论本文内容。

## 参考文献

- [1] Wikipedia: Sum of normally distributed random variables,  
[https://en.wikipedia.org/wiki/Sum\\_of\\_normally\\_distributed\\_random\\_variables](https://en.wikipedia.org/wiki/Sum_of_normally_distributed_random_variables)
- [2] SciPy Documentation: `scipy.optimize.minimize`,  
<https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.minimize.html>
- [3] Wikipedia: Inequality between any two power means,  
[https://en.wikipedia.org/wiki/Generalized\\_mean#Inequality\\_between\\_any\\_two\\_power\\_means](https://en.wikipedia.org/wiki/Generalized_mean#Inequality_between_any_two_power_means)
- [4] SciPy Documentation: `scipy.optimize.differential_evolution`,  
[https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.differential\\_evolution.html](https://docs.scipy.org/doc/scipy/reference/generated/scipy.optimize.differential_evolution.html)